《多模态大模型原理与应用》

Lecture 2
多模态大模型的发展与演进

刘阳
中山大学
人机物智能融合实验室（HCP Lab）
liuy856@mail.sysu.edu.cn

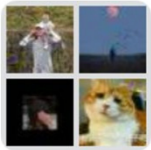

群聊：多模态大模型课程群-26春季

该二维码7天内(3月12日前)有效，重新进入将更新

本节内容

CONTENTS

一、GPT系列演进

二、Gemini原生多模态

三、DeepSeek国产大模型

四、Qwen多模态大模型

Transformer的诞生

Attention Is All You Need —— 开启NLP新纪元

论文核心贡献

- Google Brain团队发表里程碑论文，首次提出完全基于注意力机制的序列转换架构
- 彻底颠覆了传统RNN/LSTM/CNN的序列建模范式，实现并行计算突破
- 在WMT 2014英德翻译任务上取得28.4 BLEU，超越所有现有方法

革命性创新

→ Self-Attention机制：序列中任意位置可直接交互，突破长距离依赖瓶颈

→ 并行计算：摒弃顺序处理，训练速度提升数个数量级

→ 可解释性：注意力权重直观展示模型关注区域

论文影响力

10万+

Google Scholar引用

100%

现代大模型采用

2017

NLP分水岭年份

"这篇论文重新定义了深度学习处理序列数据的方式"

Transformer架构解析

编码器-解码器结构与核心组件

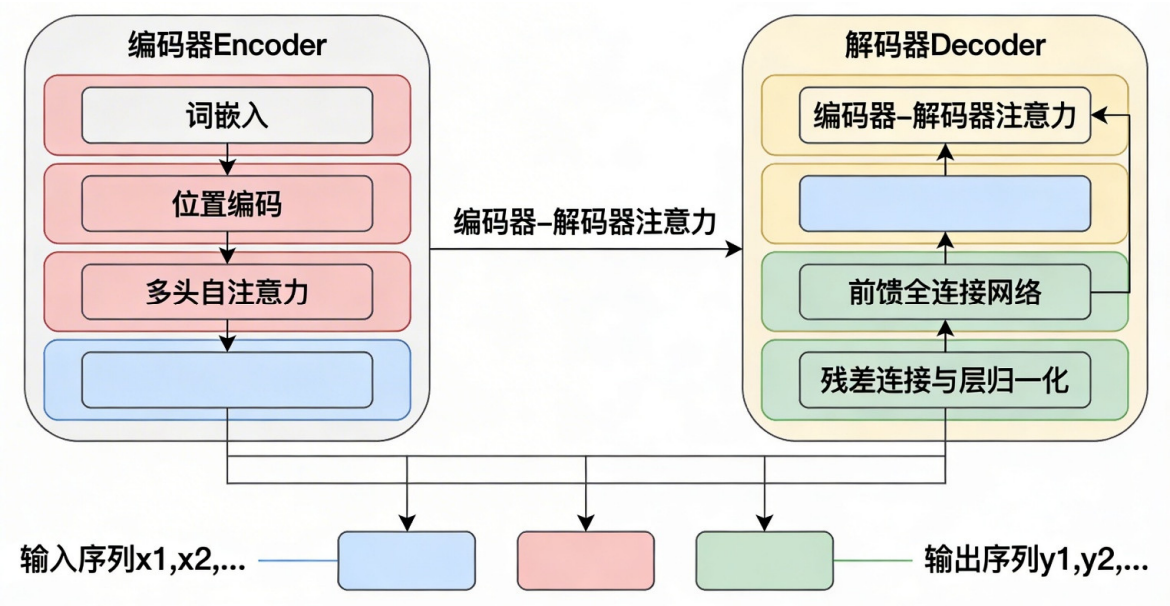

编码器（Encoder）

由N个相同层堆叠，每层包含多头自注意力子层和前馈神经网络子层，处理输入序列并提取特征表示

解码器（Decoder）

同样N层堆叠，额外包含编码器-解码器注意力子层，支持自回归生成，逐步输出目标序列

核心组件

- 多头自注意力：并行计算多组注意力
- 前馈网络：逐位置非线性变换
- 残差连接：缓解梯度消失问题
- 层归一化：稳定训练过程

关键优势：完全并行计算 + 长距离依赖建模能力

自注意力机制（QKV）

查询-键-值机制：捕捉序列内元素间依赖关系

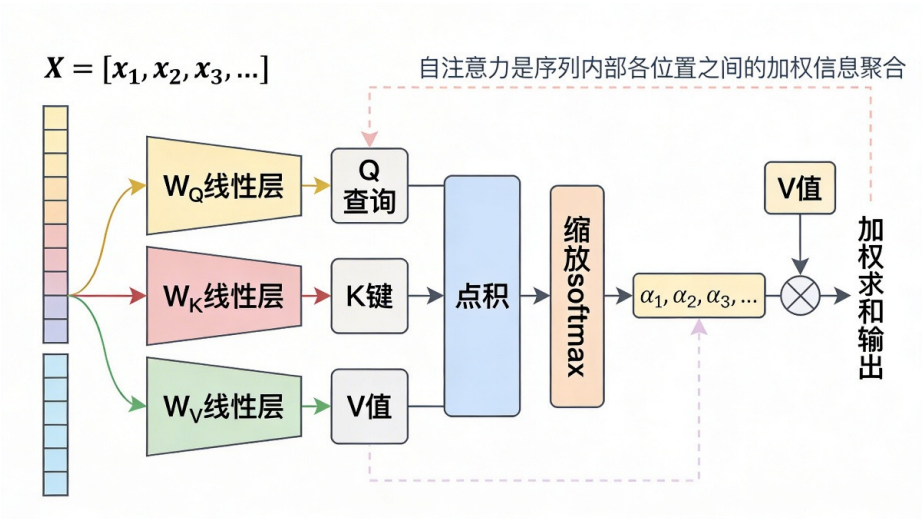

核心公式

$$\text{Attention}(Q,K,V) = \text{softmax}(QKT/\sqrt{d})V$$

Q (Query) 查询向量	K (Key) 键向量	V (Value) 值向量

计算流程

1. 将输入向量分别与WQ、WK、WV矩阵相乘，得到Q、K、V
2. 计算Q与KT的点积，除以√dk进行缩放
3. 应用softmax函数获得注意力权重
4. 将权重与V相乘，得到最终输出

★ **核心优势：并行计算 + 全局视野 + 可解释性强**

NLP的困境（2018年）

缺乏像ImageNet那样的预训练范式

CV领域的成功

ImageNet（2009） 1400万图像

大规模标注数据集 + 预训练模型（VGG、ResNet）→ 下游任务微调

↓ 范式：预训练 → 微调（Pre-train & Fine-tune）

✓ CV任务普遍采用预训练模型作为骨干网络

NLP领域的困境

✗ 问题1：缺乏统一预训练数据集

NLP任务多样，难以构建像ImageNet那样的通用标注数据集

✗ 问题2：任务专用模型

每个NLP任务从零训练，无法共享通用语言特征

✗ 问题3：数据效率低下

小数据集训练导致模型泛化能力差

领域对比

CV预训练普及度 95%

NLP预训练普及度（2018前）10%

GPT-1的解决思路

通过无监督语言建模学习通用特征，再微调适应下游任务

核心洞察：语言模型本身就是特征提取器

> "NLP需要一个ImageNet时刻"
> — GPT-1论文动机

GPT-1的核心思想：生成式预训练

GPT-1 2018年6月

通过语言建模学习通用表示

核心思想

利用无监督语言建模任务，在大规模未标注文本上预训练，学习通用的语言表示，再通过微调适应各种下游NLP任务

$$L1(\mathcal{U}) = \Sigma i \log P(ui \mid ui\text{-}k,\ldots,ui\text{-}1; \Theta)$$

最大化似然估计：预测下一个词的概率

模型规格

1.17亿 参数总量	12 Transformer层
768 隐藏层维度	512 上下文窗口

技术实现

- ✓ 无监督预训练：在BooksCorpus（约5GB，8000万句）上训练
- ✓ Transformer Decoder：仅使用解码器部分，12层，单向注意力
- ✓ 自回归建模：基于前文预测下一个词，建模语言概率分布

历史意义

- ★ 首次证明生成式预训练在NLP任务上的有效性
- ★ 开启"预训练+微调"范式，为后续模型奠定基础
- ★ 在12个下游任务中的9个取得SOTA成绩

关键洞察：语言模型学到的特征具有通用性和可迁移性

GPT-1模型结构图解

12层Transformer Decoder堆叠架构

GPT-1架构示意图

输入嵌入层
Token Embedding + Positional Encoding

↓

Transformer Decoder Block × 12

Masked Multi-Head Self-Attention	Feed-Forward Network
Layer Normalization	Residual Connection

↓

输出层
Linear + Softmax → 词表概率分布

关键设计特点

1. 仅Decoder：使用Transformer的解码器部分，去除编码器-解码器交叉注意力
2. Masked Attention：单向注意力，每个位置只能看到前文，适合生成任务
3. 层归一化后置：在每个子层之后应用LayerNorm（GPT-2改为前置）

训练数据

BooksCorpus
7000余本未出版书籍，长程依赖结构　　约5GB

数据特点
- 连续文本流，适合语言建模
- 多样化主题，覆盖广泛领域
- 高质量文本，经过筛选清洗

架构选择：Decoder-only设计成为后续GPT系列的标准

下游任务适配（微调）

通过输入改造实现多任务微调

分类任务

[Start] 文本 [Extract] → 标签

示例： 情感分析、主题分类
在文本前后添加特殊标记，模型提取特征后分类

蕴含任务

[Start] 前提 [Delim] 假设 [Extract]

示例： 自然语言推理（NLI）
用分隔符连接前提和假设，判断逻辑关系

相似度任务

[Start] 文本1 [Delim] 文本2 [Extract]

示例： 语义相似度判断
比较两个文本的语义相关性，输出相似度分数

多项选择

[Start] 上下文 [Delim] 答案 [Extract]

示例： 阅读理解、常识推理
将每个选项与上下文配对，选择概率最高的答案

统一范式： 通过特殊标记（Start、Delim、Extract）将不同任务统一为语言建模形式

微调总结

GPT-1证明预训练+微调范式的有效性

核心贡献

★ 通用特征提取
预训练模型学到通用的语言表示，可迁移到多种任务

★ 数据效率提升
微调阶段只需少量标注数据即可取得优异性能

★ 统一架构
相同模型结构通过输入改造适配不同任务

★ 性能突破
在9/12个NLP任务上超越任务专用模型

开启NLP预训练时代

前 每个任务从零训练，数据需求大，泛化能力差

↓

后 预训练+微调，数据效率高，通用性强

性能表现

文本分类 Stanford Sentiment Treebank	91.3%
语义相似度 Quora Question Pairs	88.5%
问答推理 SQuAD	74.8%

"GPT-1开创性地证明了生成式预训练在NLP领域的巨大潜力，为后续大模型发展奠定了重要基础。"

— 学术界共识

GPT-2的飞跃

GPT-2 2019年2月

参数扩大10倍，探索Zero-shot学习

参数规模对比

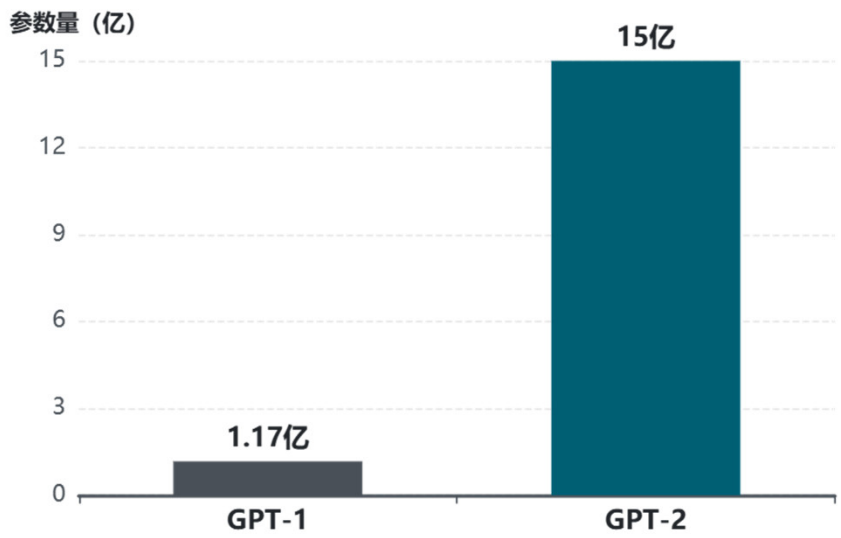

规模提升

15亿 参数量 GPT-1: 1.17亿	**48** Transformer层 GPT-1: 12层
1600 隐藏层维度 GPT-1: 768	**1024** 上下文窗口 GPT-1: 512

核心理念转变

无监督多任务学习
模型够大、数据够多，无需微调也能完成多种任务

Zero-shot学习探索
通过自然语言提示词直接完成任务，无需任务特定训练

训练数据：WebText（40GB，Reddi t高赞链接过滤）

Zero-shot的魔法

零样本学习：无需微调，通过提示词完成任务

核心概念

模型在训练时从未见过特定任务的标注数据，仅通过自然语言描述的任务提示，就能理解并执行该任务

关键洞察：大规模语言模型在预训练过程中隐式学习了任务执行能力

翻译任务示例

提示词（Prompt）：
translate to french: The cat sat on the mat.

↓

模型输出：
Le chat s'est assis sur le tapis.

Zero-shot能力展示

- **机器翻译**
  支持多语言互译，无需平行语料训练
- **文本摘要**
  生成文章摘要，理解核心内容
- **问答系统**
  基于上下文回答问题
- **情感分析**
  判断文本情感倾向

Prompt雏形

GPT-2首次展示了Prompt Engineering的潜力，为后续InstructGPT和ChatGPT的提示词优化奠定了基础

理念转变：从"训练模型做任务"到"告诉模型做什么"

数据清洗（WebText）

高质量数据的重要性

WebText构建流程

1. **爬取Reddit高赞链接**
   筛选Reddit上获得3个以上 karma 的外链，确保内容质量

↓

2. **提取文本内容**
   使用Dragnet工具提取网页正文，去除导航、广告等噪声

↓

3. **去重与过滤**
   删除重复内容，过滤低质量文本，最终得到40GB高质量数据

WebText统计

40GB	数据总量
800万+	文档数量
3+	Reddit Karma阈值

质量控制

- ✓ 用户投票机制筛选高质量内容
- ✓ 多样化主题覆盖，避免偏见
- ✓ 去除维基百科等测试集污染

⚠ 核心原则：数据质量决定模型上限，WebText的质量显著优于未过滤的Common Crawl

> "高质量的数据是训练高性能语言模型的关键"

GPT-2的架构改进

层归一化前置

GPT-1：后置LayerNorm
每个子层输出后应用LayerNorm

x → SubLayer → LayerNorm → Output

↓

GPT-2：前置LayerNorm
每个子层输入前应用LayerNorm

x → LayerNorm → SubLayer → Output

优势：更稳定的梯度流，更好的训练稳定性

其他微调

残差层初始化调整

修改残差连接权重初始化方式，提升深层网络训练稳定性

词汇表扩展

使用更大的BPE词汇表（50257 vs 40478），
提升多语言支持

上下文窗口扩大

512	1024
GPT-1 tokens	GPT-2 tokens（2倍）

影响

- 支持更长文档建模
- 提升长程依赖捕捉能力
- 增强上下文理解

性能提升

LAMBADA语言建模 GPT-1: 8.6%，提升7.4倍	63.2%
COPD常识推理 超越监督学习方法	71.2%

GPT-2小结

核心关键词

- Zero-shot 零样本学习
- Prompt 提示词雏形
- 多任务学习 无监督多任务

历史贡献

1. **证明规模的力量**
   15亿参数模型展示出强大的零样本学习能力，验证了"规模即性能"的假设
2. **Prompt Engineering萌芽**
   首次系统展示自然语言提示词引导模型完成任务的潜力
3. **数据质量意识**
   WebText的构建确立了高质量数据筛选的重要性

核心洞察

模型即任务执行器

当模型足够大、数据足够多时，语言模型本身就具备了执行多种任务的能力，无需专门训练

语言即接口

自然语言成为人与模型交互的通用接口，通过文本描述即可指定任务

后续影响

- → 启发了GPT-3的Few-shot学习探索
- → 为InstructGPT的指令微调奠定基础
- → 推动了Prompt Engineering研究领域

> "GPT-2让我们看到了大规模语言模型的惊人潜力"

GPT-3的规模震撼

GPT-3 2020年5月

1750亿参数，实现质的飞跃

参数规模指数增长

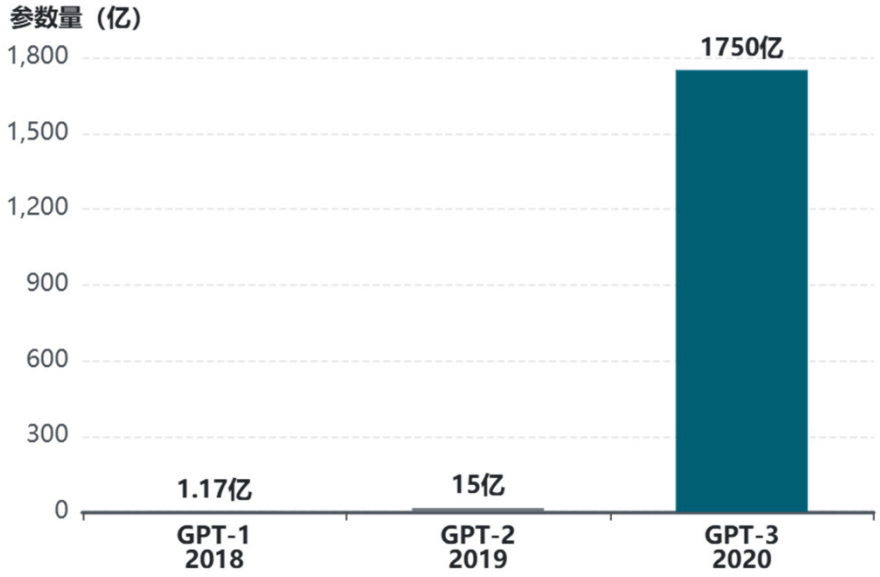

规模对比

15亿 GPT-2	1750亿 GPT-3（×117）

参数量激增带来上下文学习能力的质变

模型规格

Transformer层数	96层
隐藏层维度	12288
注意力头数	96个
上下文窗口	2048 tokens

训练成本：约355年GPU时间，成本超过1200万美元

训练数据构建

从45TB Common Crawl过滤出570GB高质量文本

三步过滤流程

1 逻辑回归筛选
训练分类器评估网页质量，保留高质量文档
特征：文本长度、标点比例、词汇多样性等

2 模糊去重
使用MinHash算法去除重复和高度相似内容
避免测试集污染，提升数据多样性

3 加入高质量数据集
补充WebText-2、Books1、Books2、Wikipedia等
采样时增加高质量数据权重

数据质量关键：过滤后数据质量显著提升，在多项任务上表现优于未过滤的同等规模数据

数据规模对比

原始Common Crawl	45TB
过滤后数据	570GB

仅保留1.3%的高质量内容

数据集组成

Common Crawl（过滤）	410GB
WebText-2	38GB
Books1	12GB
Books2	55GB
Wikipedia	3GB

采样策略：高质量数据集（如Wikipedia）被多次采样，低质量数据降低采样频率

In-Context Learning（上下文学习）

通过Few-shot示例引导模型，无需参数更新

核心机制

模型在推理时根据提供的上下文示例调整输出行为，无需梯度更新或参数微调，仅通过前向传播完成任务学习

关键洞察：大模型具备从上下文快速学习新任务模式的能力

三种学习模式对比

0 Zero-shot
直接给出任务描述，不提供示例

1 One-shot
提供1个输入-输出示例

K Few-shot（K个示例）
提供K个示例（通常10-100个），K越大效果越好

翻译任务示例

English: How are you?
French: Comment allez-vous?
English: Good morning
French: Bonjour
English: Thank you
French: ?

模型输出：Merci

性能趋势

Zero-shot	基准性能
One-shot	+15-20%
Few-shot (K=10)	+25-35%
Few-shot (K=50)	+40-50%

范式转变：从"训练时学习"到"推理时学习"

从参数更新到提示工程

学习方式的革命性转变

范式对比

传统微调

- 需要大量标注数据
- 梯度更新模型参数
- 每个任务一个模型
- 训练时间长、计算成本高
- 可能遗忘预训练知识

上下文学习

+ 仅需少量示例
+ 无需参数更新
+ 一个模型多任务
+ 推理时即时适应
+ 保留预训练能力

提示工程的重要性

提示设计
精心构造输入格式引导模型行为

示例选择
挑选代表性示例提升学习效果

示例排序
示例顺序影响模型推理结果

关键优势

即时适应
推理时根据提示即时调整行为，无需重新训练

任务通用性
同一模型通过不同提示完成不同任务

成本降低
省去微调的计算资源和时间成本

性能对比

微调GPT-2 需要训练数据和计算资源	68.5%
Few-shot GPT-3 无需训练，仅提供示例	75.2%

GPT-3的局限（生成质量）

语义重复

问题表现

- 同一概念用不同方式反复表达
- 句子结构重复，缺乏变化
- 长篇生成中内容循环

示例：

"人工智能正在改变世界。AI技术正在改变我们的生活。机器学习正在改变各行各业..."

原因：自回归生成缺乏全局规划，注意力机制过度关注近期内容

逻辑断裂

问题表现

- 长篇生成失去主题连贯性
- 前后观点矛盾或不一致
- 偶尔包含不连贯句子

示例：

"气候变化是当今最重要的环境问题。我们需要采取行动。我最喜欢的颜色是蓝色。全球变暖影响生态系统..."

原因：上下文窗口有限，长距离依赖建模不足

其他问题

- **事实错误**
  生成看似合理但实际错误的信息
- **偏见放大**
  训练数据中的偏见被模型学习并放大
- **有害内容**
  可能生成不当、冒犯性或有害文本

影响范围

短篇生成（<100词） 连贯性好，语义清晰	质量较高
中篇生成（100-500词） 偶有不连贯，需要人工审核	中等质量
长篇生成（>500词） 逻辑断裂风险高，重复严重	质量下降

GPT-3的局限（算法与结构）

双向任务表现差，缺乏常识物理

单向自回归结构的局限

不适合双向任务

- 填空任务：只能看前文，无法利用后文信息
- 词语比较：WiC任务表现差（准确率低20%+）
- 自然语言推理：ANLI任务表现不佳

缺乏深层理解

- 表面模式：依赖统计关联而非真正理解
- 上下文敏感：相同问题不同表述答案不一致
- 推理链断裂：多步推理容易出错

常识与物理推理缺陷

问题示例：

"把奶酪放进冰箱，它会融化吗？"

GPT-3可能回答："会，因为冰箱温度高" ✗

正确答案："不会，冰箱低温会保持奶酪固态" ✓

物理常识	社会常识	时序推理
物体属性、因果关系	社会规范、文化知识	事件顺序、时间关系

基准测试表现

WiC（词语比较）	52.1%
随机水平：50%，几乎无提升	
ANLI（自然语言推理）	43.8%
人类水平：90%+	
HellaSwag（常识推理）	78.5%
人类水平：95%+	

根本原因

- 语言建模目标 ≠ 理解目标
- 单向注意力限制信息利用
- 训练数据缺乏结构化知识

解决方向：需要结合知识图谱、多模态信息、强化学习等方法

GPT系列演进时间轴

从预训练到Zero-shot再到Few-shot的技术演进

2018 — **GPT-1**

核心创新

预训练+微调范式

- 1.17亿参数
- BooksCorpus数据
- 12层Transformer
- 下游任务微调

GPT-1里程碑

开启NLP预训练时代，证明生成式预训练的有效性

2019 — **GPT-2**

核心创新

Zero-shot学习

- 15亿参数（×10）
- WebText数据
- 48层Transformer
- 提示词驱动

GPT-2里程碑

展示规模的力量，Zero-shot能力初现

2020 — **GPT-3**

核心创新

Few-shot上下文学习

- 1750亿参数（×117）
- 570GB过滤数据
- 96层Transformer
- 无需微调

GPT-3里程碑

上下文学习革命，大模型时代正式到来

核心问题：Misalignment

模型与人类意图对齐问题

目标不一致问题

语言模型目标

预测下一个词

- 最大化训练数据似然
- 模仿训练数据分布
- 生成"合理"的文本

人类期望目标

3H原则

- ✓ Helpful：有帮助的
- ✓ Honest：诚实的
- ✓ Harmless：无害的

Misalignment表现

生成有害内容
偏见、歧视、不当建议

编造虚假信息
幻觉、事实错误

理解错误意图
答非所问、过度推断

缺乏可控性
输出风格不稳定

解决思路

强化学习微调（RLHF）
通过人类反馈训练奖励模型，引导模型输出符合人类偏好的回答

指令微调（Instruction Tuning）
在多样化指令数据上微调，提升指令理解和执行能力

安全训练
过滤有害数据，加入安全约束，降低风险输出

→ 引出InstructGPT

为解决Misalignment问题，OpenAI提出InstructGPT，引入RLHF技术对齐模型与人类偏好

结果：InstructGPT成为ChatGPT的核心技术基础

RLHF三步法概览

RLHF：ChatGPT智能涌现的关键

RLHF完整流程

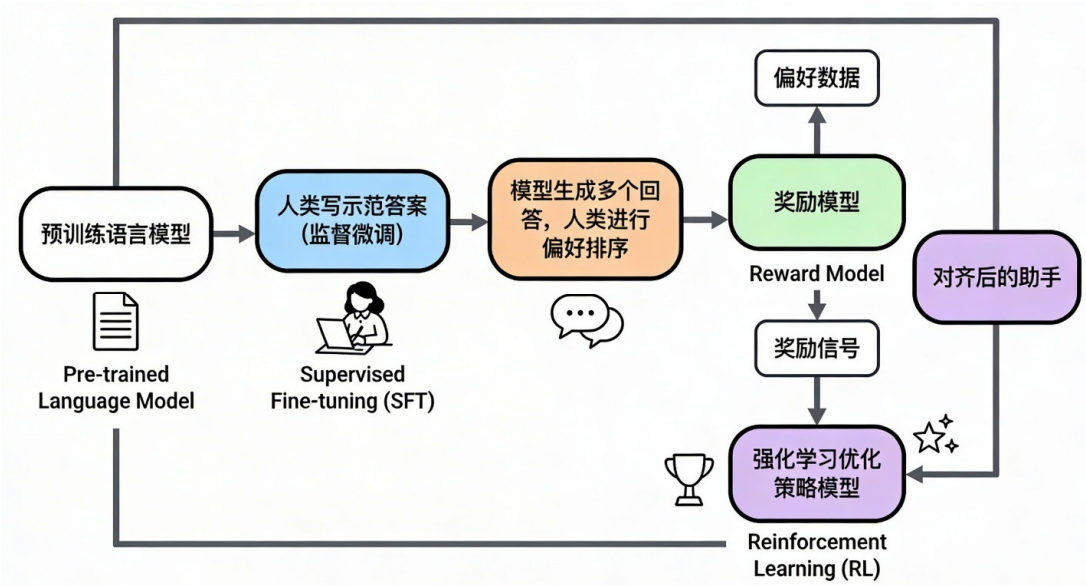

★ **核心思想：将人类偏好转化为奖励信号，通过强化学习引导模型行为对齐人类期望**

1 Step 1：SFT

监督微调（Supervised Fine-Tuning）

- 收集人类编写的高质量问答对（13k条）
- 在GPT-3基础上进行有监督微调
- 训练16轮，学习人类回答风格

2 Step 2：RM

奖励模型训练（Reward Model）

- 对同一提示生成多个答案
- 人工排序答案质量（33k提示）
- 训练6B参数奖励模型打分

3 Step 3：PPO

强化学习优化（Proximal Policy Optimization）

- 使用PPO算法优化策略
- 奖励模型提供反馈信号
- KL惩罚防止模型偏离太远

Step 1：收集演示数据

雇佣标注员编写高质量问答对

数据收集流程

1. **标注员筛选**
   雇佣40名专业标注员，通过测试确保标注质量，提供详细标注指南
2. **提示设计**
   设计多样化提示，覆盖开放问答、分类、生成、头脑风暴等多种任务类型
3. **答案编写**
   标注员编写理想答案，要求有帮助、诚实、无害，体现人类偏好

数据特点

多样性
覆盖多种任务类型和领域，避免单一化

高质量
人工精心编写，经过多轮审核

对齐性
体现3H原则（Helpful, Honest, Harmless）

可扩展
持续收集，迭代优化数据质量

数据统计

~13k
问答对总数

40
专业标注员

多轮
审核流程

训练SFT模型

使用收集的演示数据对GPT-3进行有监督微调

- 学习率：余弦衰减，最大2.6e-5
- 训练轮数：16个epoch
- 批次大小：32

过拟合现象：1轮后验证损失上升，但更多轮次提升奖励模型分数

训练SFT模型

在标注数据上微调GPT-3

训练配置

优化器 β1=0.9, β2=0.95, weight decay=0.1	AdamW
学习率调度 最大学习率：2.6e-5， warmup 3%	余弦衰减
批次大小 序列长度：2048 tokens	32
训练轮数 尽管1轮后验证损失过拟合	16 epochs

过拟合现象

验证损失上升

训练1个epoch后，验证集损失开始上升，表明模型过拟合训练数据

奖励模型分数提升

尽管验证损失上升，但人类评估和奖励模型分数持续提升

解释：过拟合的是语言建模目标，但对齐人类偏好的能力在提升

SFT模型效果

人类偏好度	+40%
指令遵循能力	显著提升
输出质量	更连贯

SFT的局限

- 标注成本高，数据量有限
- 难以覆盖所有场景和边缘情况
- 需要更强的反馈机制 → 引出RM

Step 2：训练奖励模型（RM）

数据收集流程

1. **生成多个答案**
   对同一提示，使用不同温度参数让SFT模型生成4-9个答案
2. **人工排序**
   标注员根据3H原则（Helpful, Honest, Harmless）对答案进行质量排序
3. **构建排序对**
   从排序结果生成对比对（好 > 差），用于训练奖励模型

奖励模型架构

模型结构
基于GPT-3 6B参数模型，移除最后的softmax层，添加标量输出头

训练目标

$$loss = -\log \sigma(r\theta(x, yw) - r\theta(x, yl))$$

最大化好答案与差答案之间的奖励差距

数据统计

~33k 排序提示数	
4-9 每提示答案数	6B 奖励模型参数

RM作用

- 自动评估：替代人工评估，自动判断答案质量
- 细粒度反馈：提供连续的奖励信号，而非二元判断
- 可扩展：可应用于无限量的生成数据

关键设计：使用6B而非175B模型，平衡计算效率和性能

Step 3：近端策略优化（PPO）

强化学习微调，优化策略

PPO算法原理

目标函数

$$L_{PPO}(\theta) = E[\min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1-\varepsilon, 1+\varepsilon)\hat{A}_t)]$$

$$r_t(\theta) = \pi_\theta(a_t|s_t) / \pi_{\theta_{old}}(a_t|s_t)$$

clipped surrogate objective

限制策略更新幅度，防止训练不稳定

优势函数 At

估计动作相对于平均水平的优势

KL惩罚项

完整目标函数

$$L(\theta) = L_{PPO}(\theta) - \beta \cdot KL(\pi_\theta \,||\, \pi_{SFT})$$

作用：

- 防止策略偏离SFT模型太远
- 保持语言能力和多样性
- 避免过拟合奖励模型

学生-老师类比

学生（策略模型）
生成答案，根据反馈改进行为

老师（奖励模型）
评估答案质量，提供奖励信号

环境
提示-答案交互过程

训练效果

人类偏好度	+60%
有害输出	-50%
事实准确性	+25%

InstructGPT的成果：小模型胜过大模型

惊人成果：1.3B的InstructGPT在人类评估中优于175B的GPT-3，证明对齐比规模更重要。

关键成果

指令遵循能力 +85%
显著提升

事实性 提升
幻觉减少

有害内容 -25%
输出降低

人类评估结果

模型对比（人类偏好率）	
1.3B InstructGPT vs 175B GPT-3	胜
1.3B InstructGPT vs 1.3B SFT	胜

核心洞察：对齐（Alignment）比规模更重要。通过RLHF，小模型可以在人类偏好上超越大模型。

对齐更重要
与人类意图对齐胜过单纯规模扩张

人类反馈关键
人类反馈是提升模型质量的关键

标准范式
RLHF成为对齐训练的标准范式

ChatGPT的诞生

历史时刻 2022年11月30日

发布背景

技术基础
基于GPT-3.5（InstructGPT演进版），采用RLHF技术对齐人类偏好

产品形态
对话式交互界面，支持多轮对话，免费开放使用

核心能力
对话建模、思维链推理、零样本泛化、代码生成

用户增长奇迹

5天	2个月
突破100万用户	突破1亿用户

超越TikTok、Instagram等，
成为史上增长最快消费应用

核心能力

对话建模
理解上下文，保持对话连贯性，支持多轮交互

思维链推理
展示逐步推理过程，提升复杂问题解决能力

零样本泛化
通过自然语言指令完成未见过的任务

代码生成
理解、编写、调试多种编程语言代码

社会影响

→ 引发全球AI应用热潮
→ 推动大模型技术普及
→ 改变人机交互范式

ChatGPT的优势

能力来源三大优势

强大的底座能力

GPT-3.5基础
1750亿参数，强大的语言理解和生成能力

代码预训练
在GitHub代码上训练，获得逻辑推理能力

大规模数据
570GB高质量文本，覆盖广泛领域

惊艳的思维链推理

逐步推理
展示中间推理步骤，而非直接给出答案

复杂问题解决
数学推理、逻辑谜题、多步推理任务

可解释性
用户可理解模型思考过程

实用的零样本能力

指令微调
在多样化指令数据上训练，提升指令遵循

即时适应
通过自然语言描述即时学习新任务

多任务通用
同一模型处理翻译、摘要、问答等多种任务

能力协同效应

底座 + RLHF
强大基础能力 + 人类偏好对齐 = 高质量输出

推理 + 对话
思维链推理 + 对话建模 = 交互式问题解决

零样本 + 指令
零样本能力 + 指令微调 = 通用任务执行器

GPT-4的飞跃

GPT-4 2023年3月

多模态能力

图像输入理解
支持图像输入，理解图像内容并生成文本描述或回答相关问题

图文混合推理
结合图像和文本信息进行推理，解决需要视觉理解的复杂任务

应用场景
图表分析、文档理解、视觉问答、图像描述生成

长文本处理

8K	32K
标准上下文	扩展上下文

2.5万字上下文容量，支持长文档分析、复杂对话、代码审查

考试表现排名

SAT Math 排名前10%	89%
Uniform Bar Exam 排名前10%	90%
GRE Verbal 排名前1%	99%
AP Biology 排名前15%	85%

高级推理

- 复杂推理：多步逻辑推理、数学证明
- 创意写作：诗歌、小说、剧本创作
- 技术文档：论文、报告、技术规范

GPT-4V的视觉能力

物体检测

识别图像中的物体类别和位置

示例：识别照片中的动物、车辆、建筑

OCR识别

提取图像中的文字内容

示例：扫描文档、街景文字、手写笔记

人脸识别

检测和识别图像中的人脸

示例：身份验证、照片管理、表情分析

验证码解密

识别和解决验证码挑战

示例：文字验证码、图像验证码

图表分析

理解并解释各类图表

示例：柱状图、折线图、饼图、流程图

地理定位

根据图像内容推断地理位置

示例：地标识别、街景定位

医学影像

分析医学图像并提供描述

示例：X光片、CT扫描、病理切片

UI理解

理解界面设计并生成代码

示例：网页截图转HTML、草图转代码

案例分析：复杂图表理解

输入

一张包含多组数据的复杂业务报表截图，包含表格、柱状图、趋势线

输出

提取所有数据点，分析趋势变化，计算增长率，总结关键洞察，生成业务建议

输入模式创新

纯文本

模式描述
仅文本输入，传统对话模式

应用场景
- 问答对话
- 文本生成
- 代码编写
- 翻译任务

输入：文本
输出：文本

单图像-文本对

模式描述
单张图像配合文本提示

应用场景
- 图像描述
- 视觉问答
- 图像分析
- 文档理解

输入：图像 + 文本
输出：文本

交错图像-文本

模式描述
多张图像与文本交替排列

应用场景
- 网页内容分析
- PPT演示理解
- 图文混排文档
- 视频帧序列

输入：[图+文+图+文...]
输出：文本

交错输入的优势

增强上下文关联
图像和文本相互补充，提供更丰富的上下文信息

处理复杂文档
可处理网页、PPT、论文等图文混排内容

多模态推理
跨模态信息融合，支持更复杂的推理任务

2024-2025最新进展：GPT-4o与o1系列

GPT-4o
2024年5月发布

"Omni"全模态模型
支持文本、图像、音频、视频实时理解和生成

响应速度质的飞跃
响应时间降至232毫秒，接近人类反应速度

成本大幅降低
相比GPT-4 Turbo，成本降低50%

实时交互能力
支持语音对话中的打断、情感识别、多轮实时交流

o1系列
2024-2025年发布

专注复杂推理任务
专为数学、科学、编程等需要深度推理的任务设计

"思维链"技术
采用Chain-of-Thought推理，模拟人类逐步思考过程

推理能力显著提升
数学证明、代码调试、复杂决策能力大幅提升

o3版本（2025）
进一步突破推理能力边界，接近专家水平

GPT-4.5预期
2025年上半年发布，进一步优化多模态能力和推理性能

GPT-5展望
2025年下半年预期，可能实现真正的AGI突破

技术方向
多模态融合、推理能力、效率优化、安全性并重

本节内容

CONTENTS

一、GPT系列演进

二、Gemini原生多模态

三、DeepSeek国产大模型

四、Qwen多模态大模型

Gemini简介

Google 2023年12月

Google Brain + DeepMind融合产物

团队背景

Google Brain
深度学习研究先驱，Transformer论文发源地

+

DeepMind
AlphaGo、AlphaFold等突破的创造者

= Gemini

命名含义

"双子座"
象征Google Brain与DeepMind两大团队的融合

定位：原生多模态模型（Natively Multimodal）

核心定位

原生多模态
从训练初期就融合文本、图像、音频、视频等多种模态

统一架构
单一模型处理所有模态，而非拼接多个专用模型

端到端训练
所有模态联合训练，实现真正的跨模态理解

模型系列

Gemini Ultra	最大能力
Gemini Pro	均衡性能
Gemini Nano	端侧部署

核心哲学：原生多模态

从一开始就在图像、音频、视频、文本上联合训练

传统方法 vs 原生多模态

传统方法：事后拼接

架构
文本模型 + 图像编码器 + 音频编码器

问题
- 各模态独立处理，信息损失
- 模态间对齐困难
- 无法深度融合

Gemini：早期融合

架构
统一模型，所有模态从底层融合

优势
- 模态间信息互补
- 避免信息损失
- 真正的跨模态理解

核心优势：模态间信息互补，避免信息损失，实现真正的跨模态推理

架构揭秘：早期融合

图像块、音频波形、文本Token统一到潜在空间

图像处理

图像块（Image Patches）
将图像分割为固定大小的块，类似文本Token

处理流程
1. 图像 → 图像块序列
2. 线性投影到潜在空间
3. 添加位置编码
4. 与文本Token统一处理

优势：保留空间信息，支持任意分辨率

文本处理

SentencePiece Tokenizer
统一的多语言Tokenizer，支持100+语言

特点
- 与图像、音频Token统一维度
- 共享嵌入空间
- 统一注意力机制处理

音频处理

原始波形（Raw Waveform）
直接处理音频波形，而非ASR转录文本

处理流程
1. 音频 → 波形采样
2. 频谱特征提取
3. 投影到潜在空间
4. 保留语调、背景音

优势：保留完整音频信息，包括语调、情感

统一潜在空间

核心设计
所有模态投影到相同的潜在空间，自注意力机制统一处理

跨模态交互
图像块可以关注文本Token，音频可以关注图像，实现真正的跨模态推理

稀疏专家混合（MoE）架构

每个Token只激活部分专家，提升效率

MoE架构示意图

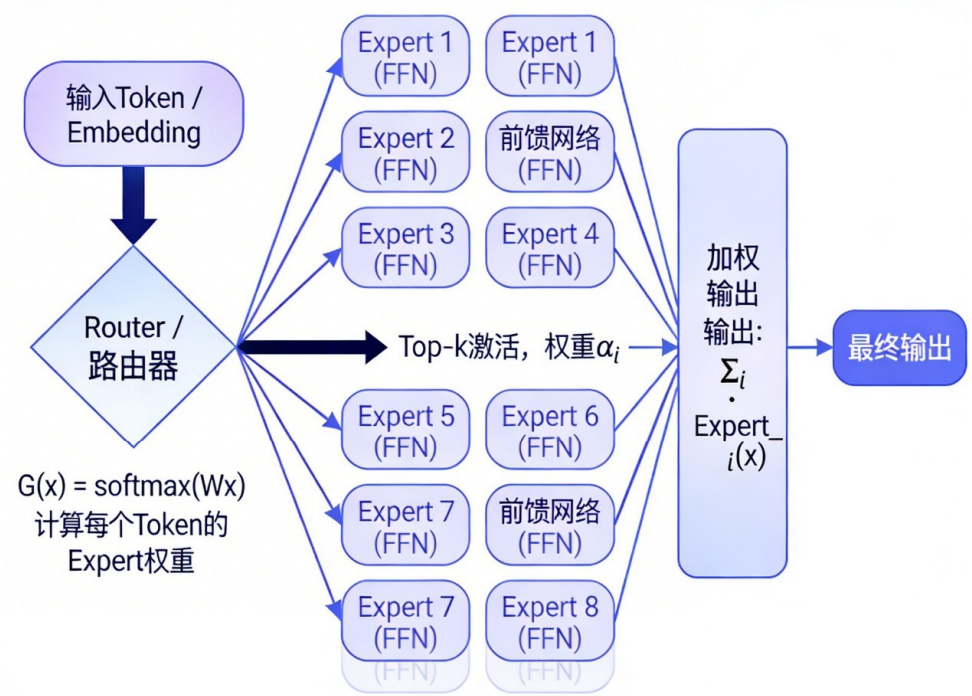

- 稀疏激活：每个Token只激活少数专家-
参数规模大但计算成本可控-
易扩展、多专家并行训练

核心公式

$$y = \Sigma i \in \mathcal{T}_k(x)\ gi(x)Ei(x)$$

gi(x)	Ei(x)	$\mathcal{T}_k$(x)
门控网络	专家网络	Top-k选择

工作机制

1. **路由决策**
   门控网络决定每个Token路由到哪些专家
2. **稀疏激活**
   每个Token只激活Top-k个专家（通常k=2）
3. **加权组合**
   专家输出按门控权重加权求和

效率优势

10倍+	相同
参数容量	推理成本

超长上下文突破（1M→10M）

支持海量信息处理

上下文规模演进

4K 早期模型
GPT-3, 早期GPT-4

↓

1M Gemini 1.5 Pro
100万tokens

↓

10M Gemini 1.5 Pro（实验）
1000万tokens

技术基础

- 稀疏注意力
  降低计算复杂度
- 高效位置编码
  RoPE, ALiBi
- 内存优化
  KV Cache优化

应用场景

1小时视频
完整理解视频内容，回答任意时间点的问题

3小时音频
会议录音、播客内容完整分析和摘要

70万字《三体》
整本书理解，人物关系分析，情节梳理

大型代码库
完整项目分析，跨文件依赖理解

意义

超长上下文让模型能够处理整本书、长视频、大型代码库，实现真正的长程理解和推理

"大海捞针"测试

百万上下文准确率99%

Needle In A Haystack测试

测试方法

在长文本中随机位置插入关键信息（"针"），测试模型能否准确召回

示例

- 文本：100万tokens的长文档
- 插入："The secret code is 2847"
- 问题："What is the secret code?"

测试难度

上下文越长，信息位置越随机，召回难度越大

Gemini 1.5表现

99%	99%
1M上下文准确率	10M上下文准确率

在百万级上下文中保持近乎完美的召回能力

对比表现

GPT-4 (32K)	~80%
Claude 2.1 (200K)	~85%
Gemini 1.5 (1M)	99%

技术突破

- 稀疏注意力：降低长序列计算复杂度
- 高效检索：快速定位关键信息
- 内存优化：高效管理长上下文状态

★ 意义：证明了百万级上下文的可行性，开启长文档处理新时代

Gemini 2.5的"思考"模式

Gemini 2.5 2024年

思考模型（Thinking Models）与隐藏思维链

思考模型机制

隐藏思维链（Hidden CoT）
生成最终答案前，模型内部先生成隐藏的思考过程，不对外展示

处理流程
1. 接收问题
2. 内部生成思维链（隐藏）
3. 基于思考生成答案
4. 输出最终回答

优势：提升推理质量，同时保持输出简洁

Deep Think模式

并行假设生成
同时探索多个推理路径，评估不同假设

更高计算成本
消耗更多算力，换取更高准确率

适用场景
复杂数学、逻辑推理、科学问题

性能提升

数学推理（MATH） 相比标准模式提升	+35%
代码生成（HumanEval） 复杂编程任务	+28%
科学问答（GPQA） 研究生级别问题	+42%

权衡

- 延迟增加：思考过程需要时间
- 成本上升：更多token生成
- 适用选择：简单任务用标准模式

智能体能力

面向智能体时代的工具调用与UI控制

工具调用

Google搜索
实时获取最新信息，回答时效性问题

Google地图
位置查询、路线规划、地点推荐

代码执行
执行Python代码，进行计算和数据分析

UI控制

界面操作
理解UI界面，模拟点击、输入等操作

任务执行
完成多步骤任务，如订票、购物

自动化工作流
串联多个操作，实现复杂自动化

向通用智能体演进

从生成到执行
不仅能生成文本，还能执行实际操作

环境交互
与外部环境（搜索、地图、应用）交互

自主决策
根据目标自主规划并执行多步骤任务

Gemini 3.0 Image Preview亮点

Gemini 3.0　2024年

图像生成与推理：先推理，再绘制

核心能力

推理驱动的生成
先生成内部推理，理解需求后再绘制图像，而非直接生成

世界建模
生成的图像符合真实世界物理规律、空间关系、逻辑一致性

文本渲染
在图像中准确渲染文字，支持标志、海报、界面设计

技术突破

统一模型
理解+生成一体化

文本理解
精确渲染文字内容

3D一致性
多视角保持一致

风格控制
精确控制视觉风格

案例：Zoom截图生成

提示词　"生成一张Zoom会议截图，包含6位科技大佬：Elon Musk、Sam Altman、Sundar Pichai、Satya Nadella、Tim Cook、Jensen Huang，他们在讨论AI的未来"

生成结果

- ✓ 6位人物身份准确
- ✓ Zoom界面元素完整
- ✓ 人物表情、姿态自然
- ✓ 背景、Logo正确
- ✓ 整体布局合理

意义

展示了"理解-推理-生成"的完整链条，图像生成进入推理驱动时代

> "先推理，再绘制"将成为图像生成的新范式

本节内容

CONTENTS

一、GPT系列演进

二、Gemini原生多模态

三、DeepSeek国产大模型

四、Qwen多模态大模型

DeepSeek是谁?

中国AI 2023-2024

中国AI新锐：高性价比、开源、技术激进

公司背景

深度求索（DeepSeek）
中国AI公司，成立于2023年，专注大语言模型研发

核心使命
致力于降低大模型使用成本，推动AI技术普惠

技术理念
通过算法创新实现效率革命，而非单纯堆砌算力

核心标签

- 高性价比
- 开源
- 技术激进

核心定位

稀疏注意力
通过稀疏注意力机制大幅降低计算成本

极致性价比
百万tokens成本降至几元钱，让中小企业用得起

开源开放
模型权重、技术细节开源，推动社区发展

代表模型

DeepSeek V2	236B MoE
DeepSeek V3	671B MoE
DeepSeek V3.2	最新版本

> "DeepSeek以效率革命引领大模型成本下降"

MLA注意力机制：Multi-head Latent Attention

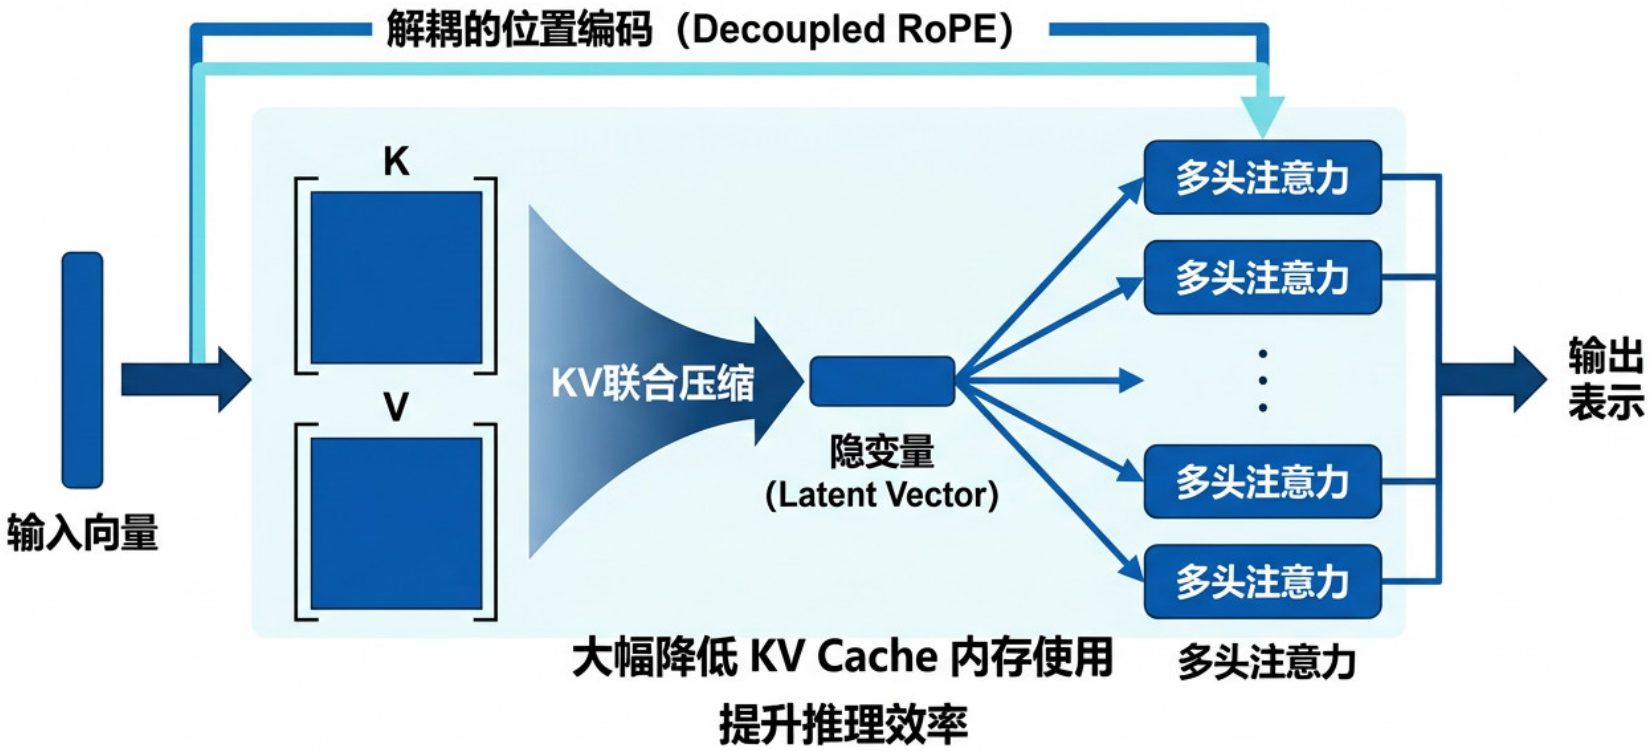

⚠传统Attention问题

- ⊗ KV缓存随头数线性增长
- ⊗ 长序列推理内存瓶颈
- ⊗ 限制batch size和上下文长度

✓MLA解决方案

- ✓ 将K、V投影到低维潜在空间
- ✓ 多个头共享潜在表示
- ✓ KV缓存大幅减少

MoE混合专家架构

Mixture of Experts（MoE）是DeepSeek实现高效大模型的关键技术

MoE示意图

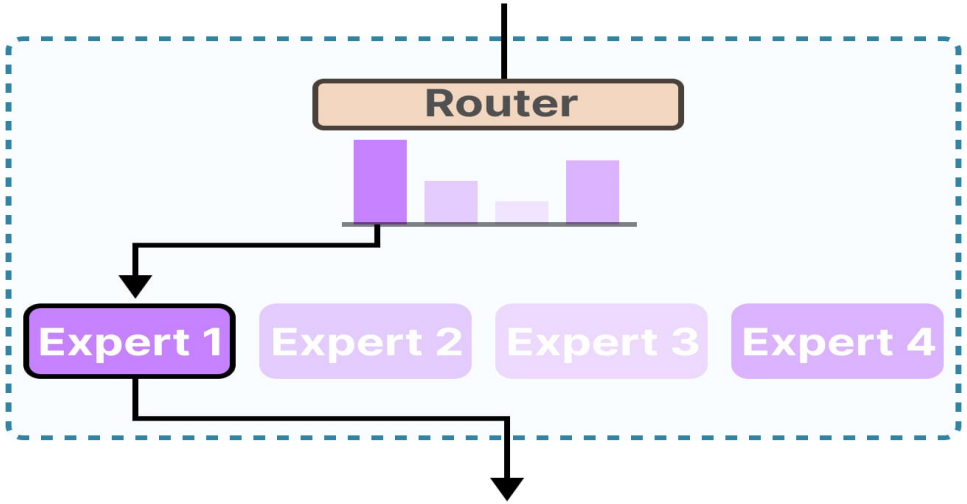

输入通过路由器分配给最合适的专家，只激活部分参数

- 传统模型：所有参数参与每次计算（密集架构）
- MoE架构：动态激活部分专家（稀疏激活）
- 核心优势：万亿参数规模下保持低计算成本

复杂度对比

标准注意力 $O(L^2)$

序列长度的平方，随长度快速增长

↓

稀疏注意力 $O(Lk)$

k << L，线性复杂度，k为常数

通俗比喻

标准注意力 = 逐个看

每个词都要与所有其他词计算注意力，像阅读时逐字仔细看每个词

稀疏注意力 = 挑重点看

只关注重要的词，忽略无关内容，像快速浏览时抓住关键词

MoE三大核心组件

1. 专家网络
多个独立的神经网络，每个专家负责特定领域任务

2. 门控路由器
智能决策器，为每个输入选择最佳专家组合

3. 负载均衡
确保各专家工作量平衡，避免资源浪费

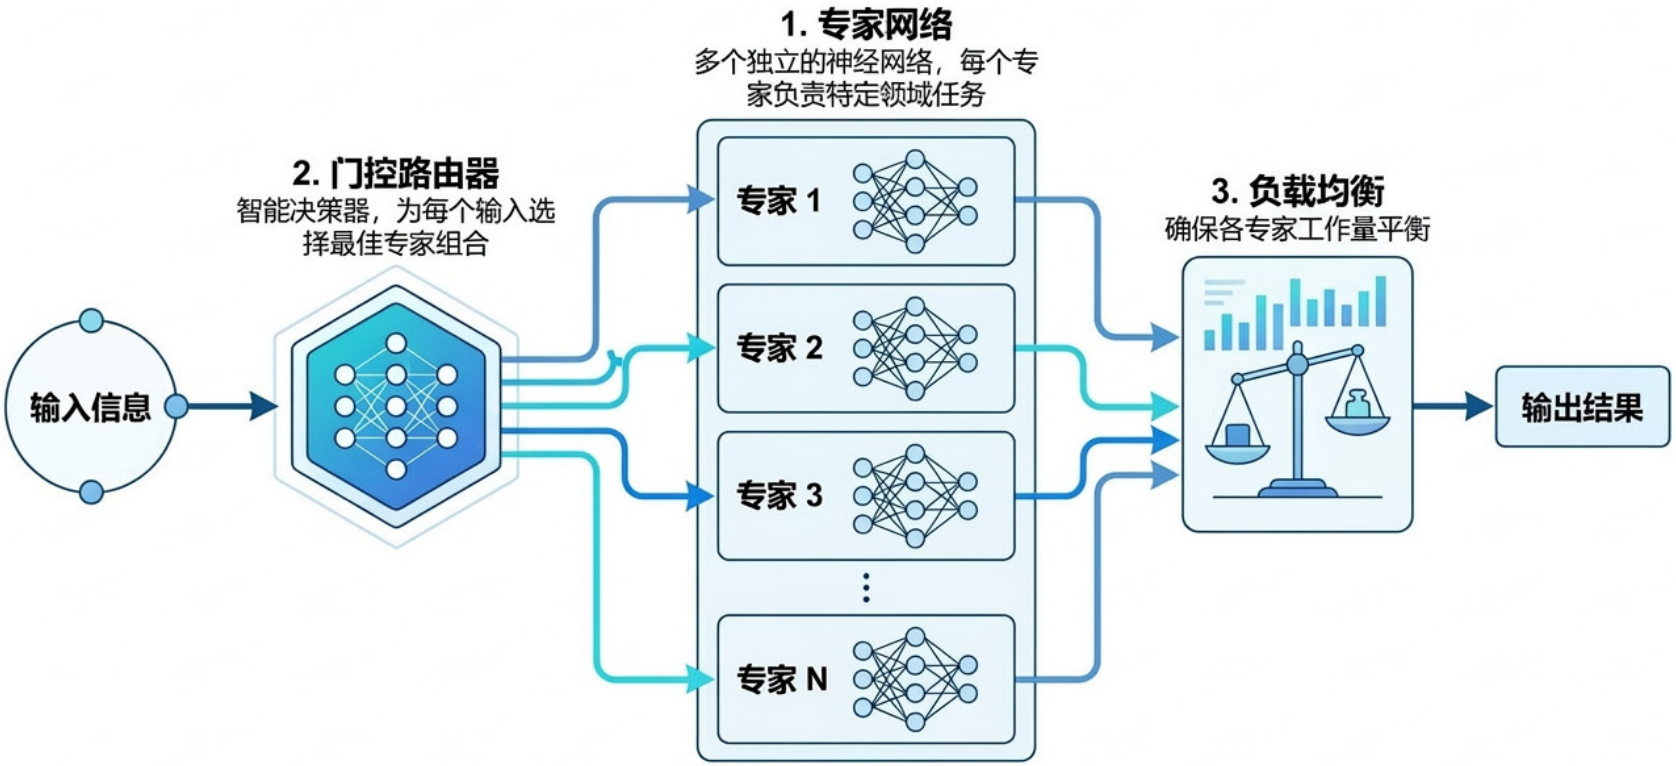

稀疏注意力机制

DeepSeek Sparse Attention（DSA）是V3.2的重大创新

- **解决长文本处理的计算瓶颈**
- **大幅降低注意力机制的复杂度**
- **保持模型性能的同时提升效率**

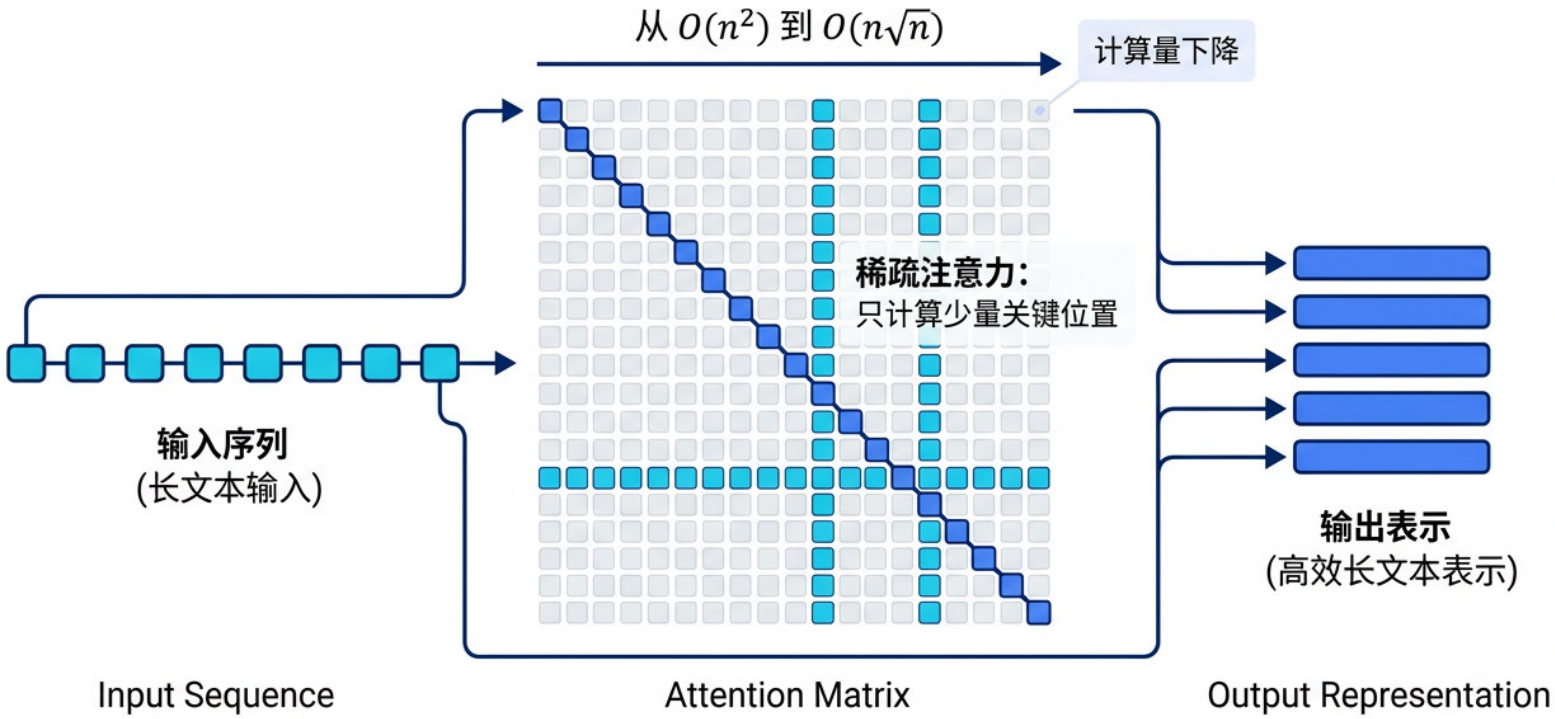

DeepSeek-R1：推理模型的革命性突破

发布时间：2025年1月。DeepSeek-R1挑战OpenAI o1，采用纯强化学习训练范式，实现推理能力的革命性突破。

核心特点

跳过SFT阶段
传统：预训练 → SFT → RL
DeepSeek-R1：预训练 → 直接RL

长思考链可见
内部推理过程可见，自我反思和纠错

推理性能优异
数学、代码、逻辑推理大幅提升

推理性能数据

AIME 2024	79.8%
MATH-500	97.3%
Codeforces	2029 Elo

媲美OpenAI o1（AIME 79.2%，MATH 96.4%）

DeepSeek-R1证明了RL可以从零开始训练推理能力，为训练推理模型提供了全新范式

DeepSeek-R1的纯RL训练：跳过SFT的大胆尝试

范式对比

传统范式
预训练 → SFT（学示范） → RL（优化）

DeepSeek-R1
预训练 → 直接RL（探索学习）

纯RL训练过程

1. 起点：预训练的DeepSeek-V3
2. 奖励设计：答案正确性、推理合理性、格式规范
3. 探索策略：高温度采样鼓励探索，逐步降温稳定
4. 涌现现象：自发产生思维链、自我验证

涌现的思维链示例

"让我仔细分析这个问题..."

"等等，这里可能有问题..."

"让我重新检查一下..."

强化学习推理系统

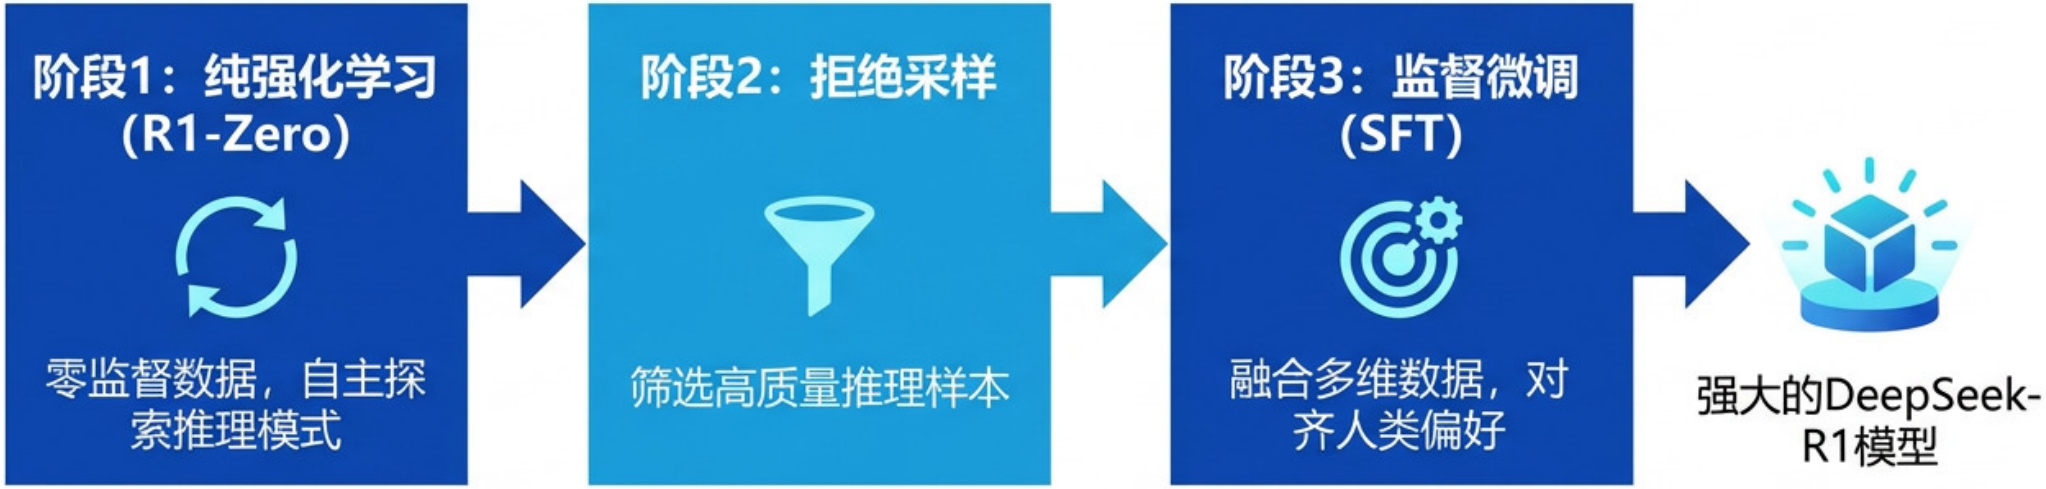

阶段1：纯强化学习（R1-Zero）

完全通过RL自主探索推理模式

阶段2：拒绝采样

筛选高质量推理样本

阶段3：监督微调

融合推理和非推理数据，对齐人类偏好

本节内容

CONTENTS

一、GPT系列演进

二、Gemini原生多模态

三、DeepSeek国产大模型

四、Qwen多模态大模型

一个思考实验：AI 能看懂这张图吗？

复杂场景示例

咖啡店场景

- 菜单板上的饮品列表与价格
- 店内装饰风格与灯光氛围
- 顾客点单场景与店员互动
- 咖啡机、杯子等物体位置

关键洞察：这张图包含文字、物体、场景、关系等多维度信息

三个挑战性问题

1. **图中有哪些商品？**
   需要 OCR文字识别 + 物体检测
2. **最贵的饮品是什么？**
   需要 价格提取 + 数值比较
3. **这家店的装修风格如何？**
   需要 场景理解 + 语义推理

这些问题需要「视觉理解 + 文字识别 + 语义推理」的融合能力 → 这就是多模态的必要性

传统 AI 的困境：单模态的"盲人摸象"

纯语言模型

✓ **能力**
聊天、写作、逻辑推理

✗ **局限**
完全看不懂图片

案例
给它看菜单照片，它说"我看不见"

纯视觉模型

✓ **能力**
图像分类、物体检测

✗ **局限**
不会对话交流

案例
识别出"咖啡杯"，但无法回答"多少钱"

多模态需求

✓ **目标**
既能看又能说

⚠ **挑战**
技术实现难度大

使命
这就是 Qwen-VL 的使命

⚠ **核心问题：如何打通视觉与语言的"任督二脉"？**

答案就在 Qwen-VL 的技术架构中

Qwen-VL 的使命：打通视觉与语言的"任督二脉

视觉理解

看懂图片/视频

语言对话

自然语言交流

多模态融合

统一理解与推理

深度理解

不仅能看懂图片/视频中的物体、文字、场景，还能理解它们之间的关系和语义

自然对话

用自然语言与用户交流，回答问题、生成描述、提供建议，像人类一样沟通

精确定位

精确指出"猫在图片左上角"，支持开放域的目标定位，不限定预定义类别

Qwen-VL = 视觉理解 + 语言对话 + 精确定位 = 真正的多模态智能

三代演进：从"看图说话"到"视频理解"

1

2023.8

Qwen-VL

图像理解

- 224×224 固定分辨率
- 4K 最大 Token
- ✕ 不支持视频

2

2024.8

Qwen2-VL

图像+短视频

- 动态分辨率
- 32K 最大 Token
- ☑ 支持短视频

3

2025.8

Qwen2.5-VL

超长视频+代理

- 任意分辨率
- 128K+ 最大 Token
- ☑ 数小时长视频

🚀 **核心演进逻辑：分辨率灵活性 ↑ × 上下文长度 ↑ × 模态支持 ↑ = 能力跃迁**

Qwen-VL（一代）：2023 年的突破

三大核心突破

1. **首个支持中文开放域定位**
   突破英文限制，直接理解中文指令
2. **细粒度视觉理解**
   精确识别图中物体的具体位置
3. **强大的 OCR 能力**
   识别复杂场景中的文字信息

代表性任务

- 图像描述
- 视觉问答
- 目标定位

实际案例：发票识别

输入：发票图片

- 商品名称列表
- 单价与数量
- 税率与金额

↓

输出：结构化信息

- 识别所有商品名称
- 提取价格与数量
- 自动计算总额

2023年：中文多模态元年，Qwen-VL 开启国产大模型新篇章

Qwen2-VL（二代）：解锁动态分辨率

关键创新

Naive Dynamic Resolution
原生动态分辨率技术

- 不再强制压缩到固定尺寸
- 保持原始长宽比不变形
- 根据图片大小动态分配 Token

能力跃迁

高清图表	长截图	短视频
支持4K分辨率	保持比例完整	理解动态内容

效果对比

一代：固定分辨率

- 强制压缩到 224×224
- 高清图表 → 细节丢失
- 长截图 → 变形失真
- 识别准确率受限

↓

二代：动态分辨率

- 保持原始长宽比
- 高清图表 → 清晰锐利
- 长截图 → 完整识别
- 识别准确率大幅提升

动态分辨率 = 量体裁衣 vs 削足适履 → 质的飞跃

Qwen2.5-VL（三代）：从工具到代理

突破 1

超长视频理解

- 处理数小时视频
- 精确定位到秒级片段
- 智能采样关键帧

案例："在第47分23秒，主角说了什么？"

突破 2

智能代理功能

- 操作手机/电脑界面
- GUI 自动化交互
- 完成复杂任务链

案例："打开淘宝，搜索蓝牙耳机，筛选200元以下"

突破 3

多语言+复杂文档

- 支持 30+ 语言
- 解析多页 PDF
- 表格图表混合文档

案例：分析跨国企业的财务报表

革命性意义

前 工具阶段

回答问题、生成描述、被动响应

后 代理阶段

主动执行任务、操作界面、完成目标

Qwen2.5-VL = 从"能看会说"到"能做事"的质变

能力对比：三代模型雷达图

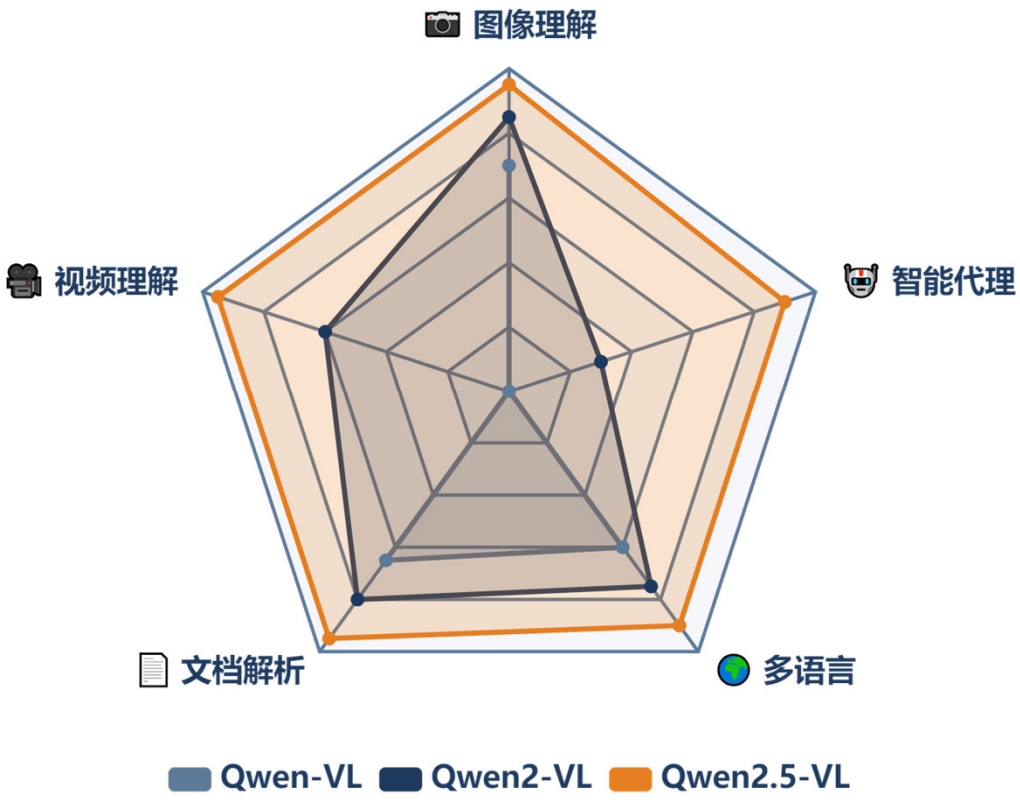

Qwen-VL（一代）

- 基础图像理解
- 固定分辨率限制
- 不支持视频

Qwen2-VL（二代）

- 动态分辨率
- 短视频支持
- 长上下文

Qwen2.5-VL（三代）

- 超长视频
- 智能代理
- 全维度领先

整体架构：三个"翻译官"的协作

摄影师（ViT 视觉编码器）

拍摄照片，提取视觉特征，将图片转换为模型能理解的特征表示

类比：像摄影师捕捉画面中的关键信息

同声传译（Adapter 适配器）

压缩视觉信息，翻译成语言模型能理解的"语言"，建立视觉-语言桥梁

类比：像同声传译将外语翻译成母语

文字记者（Qwen LLM）

理解翻译后的信息，生成自然语言回答，完成最终的推理与输出

类比：像记者理解信息后撰写报道

完整数据流

核心公式

Qwen-VL = ViT + Adapter + LLM

为什么需要 Adapter？信息压缩的必要性

不压缩的问题

显存爆炸

一张高清图片 → 5000+ 视觉 Token，处理一张图需要 100GB+ 显存

注意力分散

语言模型"消化不良"，无法有效处理海量视觉信息

计算缓慢

推理时间增加 10 倍以上，无法实际应用

Adapter 解决方案

压缩到 256 Token

压缩比达到 20:1，大幅提高效率

- ✓ 保留关键信息
- ✓ 保持位置关系
- ✓ 计算效率提升

对比数据

Token 数量	显存占用	推理速度
5000+	100GB+	5秒/图
→	→	→
256	8GB	0.5秒/图

双视觉编码器：既见森林又见树木

人类看画的两个层次

粗看（高层语义）
"这是日落海滩"

细看（底层细节）
"沙滩上有贝壳"

Qwen-VL 的设计

高层编码器 → 语义特征
全局理解、场景识别

+

低层编码器 → 细节特征
局部细节、文字识别

↓

特征融合

优势对比

案例：建筑图纸识别

单编码器	双编码器
✓ 识别"这是建筑图纸"	✓ 识别"这是建筑图纸"
✗ 漏读标注数字	✓ 精确读取尺寸标注

核心优势

- 全局+局部：同时捕捉高层语义和底层细节
- 互补性：两个编码器相互补充，信息更完整
- 精确度：在 OCR、目标定位等任务上表现更优

双编码器 = 粗看+细看 = 全局理解+局部精确

Vision-Language Adapter：智能压缩的"翻译官"

工作原理

输入：5000+ 视觉 Token + 位置编码

↓

Position-aware 交叉注意力
智能选择关键信息，保留位置关系

↓

输出：256 Token（压缩比 20:1）

关键特性

- 保留空间关系："左上角是标题"
- 保留重要细节："签名在右下角"
- 固定输出长度：便于语言模型处理

类比理解

普通压缩

像把照片缩小（信息丢失）

简单粗暴的降采样，丢失细节和位置信息

Adapter 压缩

像画简笔画（抓住关键特征）

智能选择关键信息，保留重要特征和位置关系

技术优势

- 智能选择：基于注意力机制，保留关键信息
- 位置感知：编码位置信息，支持精确定位
- 可学习：通过训练优化压缩策略

动态分辨率（上）：Qwen2-VL 的革命性创新

传统方法的问题

强制压缩到 224×224

无论原始图片多大，都强制压缩到固定尺寸

- ✗ 高清图表 → 细节丢失
- ✗ 长截图 → 变形失真
- ✗ 宽屏照片 → 比例破坏

类比：削足适履（强行塞进固定尺码）

传统方法 = 削足适履

不顾实际情况，强行适配固定框架

Qwen2-VL 的解决方案

Naive Dynamic Resolution

原生动态分辨率技术

- ✓ 保持原始长宽比
- ✓ 动态分配 Token 数量
- ✓ 分辨率越高 → Token 越多

类比：量体裁衣（根据实际定制）

动态分辨率 = 量体裁衣

根据实际尺寸，灵活调整处理策略

动态分辨率（下）：实际效果对比

案例 1：名片识别

固定分辨率
文字模糊，识别率 60%

动态分辨率
清晰锐利，识别率 95%

案例 2：长截图

固定分辨率
压缩变形，漏读内容

动态分辨率
保持比例，完整识别

案例 3：数据图表

固定分辨率
坐标轴数字看不清

动态分辨率
精确解析每个数据点

核心数据提升

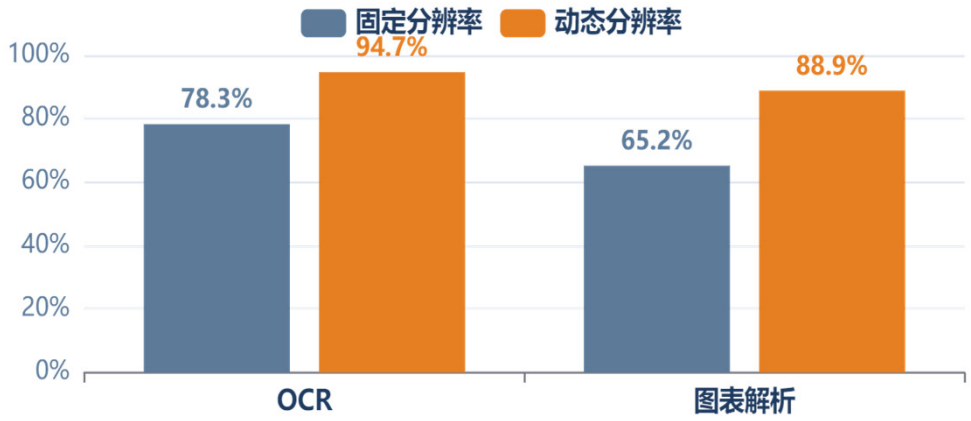

OCR 任务 +16.4%
78.3% → 94.7%

图表解析 +23.7%
65.2% → 88.9%

M-RoPE：多模态旋转位置编码

问题：动态分辨率下如何保持位置信息？

1. 图像不同区域的空间位置
2. 视频不同帧的时间顺序
3. 文本不同段落的逻辑关系

M-RoPE 解决方案

2D 位置编码（图像 x, y 坐标）
标注图像中物体的空间位置

1D 时间编码（视频帧序列）
记录视频帧的时间先后顺序

1D 文本编码（字词顺序）
保持文本的序列关系

类比：GPS 定位系统

GPS 定位

- 无论你在哪里（分辨率多大）
- 都能准确标注坐标（位置信息）

技术优势

- 统一处理：图像、视频、文本统一编码
- 任意长度：支持任意分辨率/时长输入
- 时空一致：保持空间-时间一致性

核心公式： M-RoPE = 2D Spatial + 1D Temporal + 1D Textual

M-RoPE = 多模态统一位置编码 = 空间+时间+文本的完整描述

视频理解机制：从图片到视频的跨越

Qwen2-VL 视频处理

视频输入

↓

均匀采样关键帧
每秒 2 帧

↓

逐帧编码
每帧当作独立图片处理

↓

时序建模
M-RoPE 编码时间顺序

↓

语言模型理解
生成视频摘要/回答问题

Qwen2.5-VL 超长视频

- **支持数小时视频**
  从几分钟到数小时的视频都能处理
- **智能采样策略**
  关键帧 + 稀疏采样，平衡效率与效果
- **精确定位**
  秒级时间戳检索，精确到具体时刻

实际案例

输入：2 小时电影
问题："主角在第 47 分 23 秒说了什么？"
输出：精确定位片段 + 生成对话内容

视频理解 = 图片序列 + 时间关系 = 动态世界的理解

技术总结：架构全景图

完整数据流与技术栈

原始输入（图片/视频）

双视觉编码器
高层+低层特征

动态分辨率处理
保持长宽比+动态Token

Vision-Language Adapter
压缩到256 Token

M-RoPE 位置编码
2D空间+1D时间+1D文本

Qwen 语言模型
多模态理解+自然语言生成

输出（回答/描述/定位）

双编码器 | 动态分辨率 | V-L Adapter | M-RoPE | Qwen LLM

阶段 1 & 2：预训练 + 多任务预训练

1 阶段 1：预训练

数据来源

50 亿原始图文对 → 清洗后 14 亿
77.3% 英文，22.7% 中文

训练策略

✓ 冻结语言模型（保护已有能力）
✓ 只训练 ViT + Adapter

目标：建立视觉-语言初步映射

2 阶段 2：多任务预训练

7 大任务

- 图像描述
- 目标检测
- 图文匹配
- 纯文本生成（防止遗忘）
- 视觉问答
- OCR 识别
- 视觉推理

训练策略

✓ 解冻全部模型联合训练
✓ 任务混合采样

为什么加纯文本任务?
→ 防止"灾难性遗忘"，保持语言推理能力

数据规模对比

阶段 1	阶段 2	阶段 3
14亿	77M	350K
图文对	任务样本	高质量对话

阶段 3：指令微调与人类对齐

3 阶段 3：指令微调

数据规模
350K 高质量对话

数据构成
- 人工标注对话
- AI 辅助生成 + 人工审核
- 拒绝有害内容的负样本

训练方法
- 监督微调（SFT）
- 人类反馈强化学习（RLHF）

数据质量控制流程

原始数据（50 亿）
↓
去重 + 过滤低质量
↓
NSFW 内容检测
↓
语言质量评估
↓
高质量数据（14 亿，保留率 28%）

质量标准

图文相关性	图像清晰度	文本完整性	安全性
> 0.85	> 720p	无乱码	无暴力/色情

核心能力全景：Qwen-VL 能做什么？

图像理解

场景描述、物体识别

89.3%
准确率

相册管理、图片搜索

视觉问答

回答图片相关问题

85.7%
准确率

智能客服、教育辅导

目标定位

精确框选物体位置

78.2%
准确率

工业检测、医疗标注

OCR 识别

场景文字识别

94.7%
准确率

文档数字化、票据录入

视频理解

视频摘要、事件检测

82.1%
准确率

内容审核、监控分析

GUI 操作

自动化界面交互

76.5%
准确率

RPA、智能助手

六大核心能力 = 从理解到行动的全方位智能

横向对比：Qwen-VL vs 其他大模型

维度	Qwen-VL	GPT-4V	Gemini Pro	DeepSeek-VL
开源性	✓ 完全开源	✗ 闭源	✗ 闭源	⚠ 部分开源
中文能力	☆☆☆☆☆	☆☆☆	☆☆☆	☆☆☆☆
高分辨率	✓ 动态分辨率	✓ 支持	✓ 支持	⚠ 有限
视频理解	✓ 超长视频	⚠ 短视频	✓ 支持	✗ 主要图像
目标定位	✓ 中文开放域	✓ 支持	⚠ 有限	✓ 支持
智能代理	✓ GUI 操作	⚠ 有限	✗ 无	✗ 无
社区支持	✓ 活跃	⚠ 官方为主	⚠ 官方为主	⚠ 发展中
成本	💰 免费	💰💰💰	💰💰	💰 免费

🏆 Qwen-VL 的独特优势

CN 中文生态最强
首个支持中文开放域定位

🔒 完全开源
代码+模型+训练细节

🔄 持续演进
阿里云持续投入

🛠 工程友好
详细文档+活跃社区

未来展望与思考：多模态 AI 的下一站

技术趋势

更长上下文
当前：处理 2 小时视频 → 未来：理解整本相册、全天监控录像

更多模态融合
视觉 + 听觉（音视频联合理解）→ 触觉 + 本体感知（具身智能/机器人）

端侧部署
在手机/IoT 设备运行多模态模型 → 实时、低延迟、保护隐私

自主智能代理
从"回答问题"到"主动完成任务" → 自动规划旅行、自动剪辑视频

开放性讨论问题

- 如果 AI 能实时理解你的屏幕，它应该被允许做什么？（隐私边界）
- 多模态模型会取代哪些职业？会创造哪些新职业？
- 如何防止技术被用于深度伪造、虚假信息传播？

课后实践

- 实践任务：用 Qwen-VL Demo 分析一张复杂图片，提交技术观察报告
- 阅读材料：Qwen-VL 官方技术博客、GitHub 仓库源码、相关学术论文

问题和讨论