《多模态大模型原理与应用》

Lecture 3
从预训练到自监督

刘阳
中山大学
人机物智能融合实验室（HCP Lab）
liuy856@mail.sysu.edu.cn

本节内容

CONTENTS

一、预训练的基本思想

二、NLP领域的预训练任务

三、计算机视觉领域的预训练任务

四、多模态场景下的预训练任务

今天的三个核心问题

Q1 如何学?

大模型如何学会语言、图像等复杂模态?

从海量无标注数据中自动学习通用表示，通过自监督任务构建监督信号，让模型掌握语言的语法语义、图像的视觉特征

自监督学习机制

Q2 什么关系?

预训练、微调、自监督之间是什么关系?

自监督是方法，预训练是过程，微调是应用。三者构成大模型训练的核心范式：先用自监督任务预训练，再用标注数据微调

技术体系架构

Q3 为什么是地基?

为什么说自监督学习是多模态大模型的地基?

自监督让模型从无标注数据中学习，突破标注瓶颈；多模态需要学习跨模态对齐，自监督提供了统一的训练框架

基础支撑作用

> **核心观点：从"如何学"到"为什么这样学"，本讲将系统梳理预训练与自监督学习的理论基础与实践方法，帮助大家建立完整的技术认知框架**

什么是预训练？

Pre-training: Definition and Motivation

定义

预训练是一种初始化框架，在大规模通用任务上训练模型，使其学习丰富的通用表示，为下游任务提供强大的起点

核心动机

1. **在大规模无标注/弱标注数据上训练**
   利用互联网级别的海量数据，突破人工标注的瓶颈
2. **学习丰富的通用表示**
   捕捉数据的底层结构与高层语义，形成可迁移的知识
3. **为下游任务提供强大起点**
   避免从零训练，加快收敛速度，提升模型性能
4. **加快收敛、减少标注需求**
   微调阶段只需少量标注数据即可达到优异效果

预训练的价值

数据效率 10-100x
相比从零训练，预训练可减少10-100倍的标注数据需求

收敛速度 5-10x
微调阶段收敛速度提升5-10倍，大幅缩短训练时间

性能提升 +20%
下游任务准确率平均提升20%以上

核心洞察
预训练的本质是"先学习通用知识，再学习特定任务"，类比人类教育中的通识教育与专业教育

预训练的基本流程

From Raw Data to Downstream Tasks

预训练 + 微调的两阶段范式

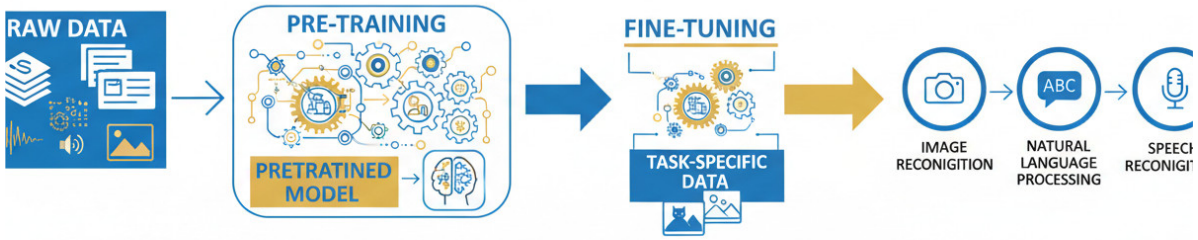

阶段 1

大规模无标注/弱标注数据预训练

- 使用海量无标注数据（如互联网文本、图像）
- 设计自监督任务生成监督信号
- 训练模型学习通用表示

阶段 2

小规模任务数据微调

- 使用特定任务的标注数据
- 在预训练权重基础上微调
- 快速适配下游任务

关键优势：两阶段分离让模型先掌握通用知识，再快速适配特定任务

预训练解决什么问题？

Why Do We Need Pre-training?

标注瓶颈

标注数据昂贵且稀缺

- 人工标注成本高昂，质量难以保证
- 专业领域标注需要专家知识
- 标注速度远低于数据生成速度

数据需求

从零训练需要海量数据

- 深度学习模型参数量巨大
- 避免过拟合需要大量样本
- 训练成本随数据量线性增长

预训练的解决方案

预训练模型可迁移到多个任务

一次预训练，多次复用，避免重复训练

提高泛化能力

学习通用特征，减少对特定任务的过拟合

提升样本效率

微调阶段只需少量标注数据即可达到优异效果

> **核心观点：预训练通过自监督学习从海量无标注数据中提取知识，克服标注瓶颈，为下游任务提供强大的特征表示基础**

代理任务的概念

Pretext Task: Learning from Self-Supervised Signals

什么是代理任务?

代理任务是人为设计的自监督任务，虽然不是最终目标，但能让模型学习到有用的特征表示

通过设计巧妙的"伪标签"，让模型从数据本身的结构中挖掘监督信号，无需人工标注

设计目的

- ✓ 让模型学习数据的内在结构和规律
- ✓ 从无标注数据中挖掘监督信号
- ✓ 学到的特征可迁移到真实下游任务

典型示例

NLP领域

预测被遮蔽的词：随机遮蔽句子中的部分词汇，让模型根据上下文预测缺失的词

CV领域

预测图像旋转角度：将图像旋转0°/90°/180°/270°，让模型判断旋转角度

拼图任务

图像拼图：将图像切成多块并打乱，让模型恢复原始排列

关键洞察：好的代理任务应该既足够困难以避免捷径解，又与下游任务语义相关

预训练的历史演进

From Word2Vec to the Era of Large Models

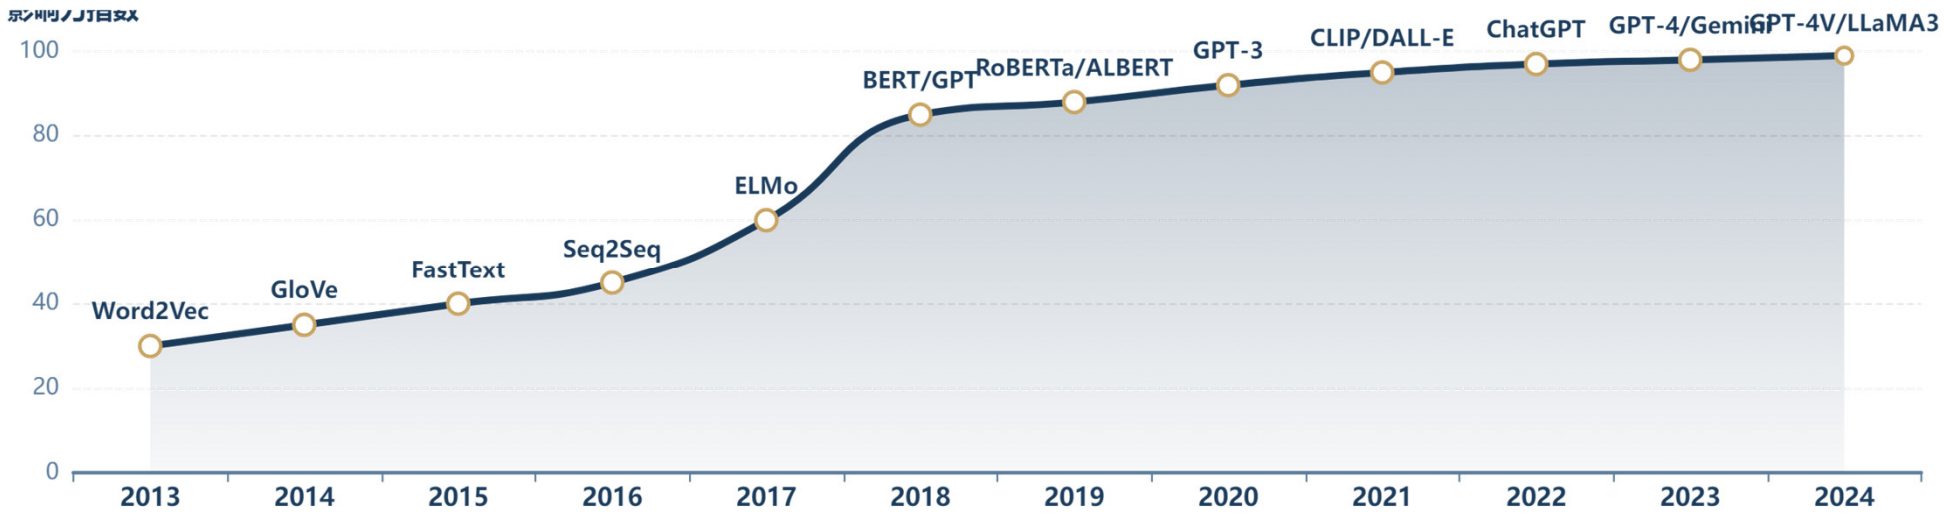

2013
Word2Vec
静态词向量时代

2017
ELMo
动态上下文表示

2018
BERT/GPT
预训练+微调范式

2020+
GPT-3/CLIP
大规模多模态

最新进展：基础模型时代

2023-2026 Representative Models

GPT-4V
OpenAI, 2023

视觉语言统一对话模型

- 支持图像输入的多模态对话
- 强大的视觉理解与推理能力
- 可处理图表、文档、照片等多种视觉内容

Gemini 1.5
Google, 2024

长上下文多模态理解

- 支持100万+ Token的上下文窗口
- 原生多模态架构，统一处理文本、图像、音频
- 强大的长文档与视频理解能力

Claude 3.5
Anthropic, 2024

多模态推理与安全对齐

- 出色的视觉推理与代码理解
- 强调AI安全与价值观对齐
- 减少有害输出，提高可靠性

LLaMA 3
Meta, 2024

开源大规模预训练基座

- 开源可商用，推动AI民主化
- 参数规模从8B到405B，覆盖多种场景
- 性能接近闭源商业模型

核心观点：预训练规模与能力同步爆发，多模态统一理解成为主流趋势，开源生态加速技术普及

预训练+微调流程图

Complete Technical Pipeline Visualization

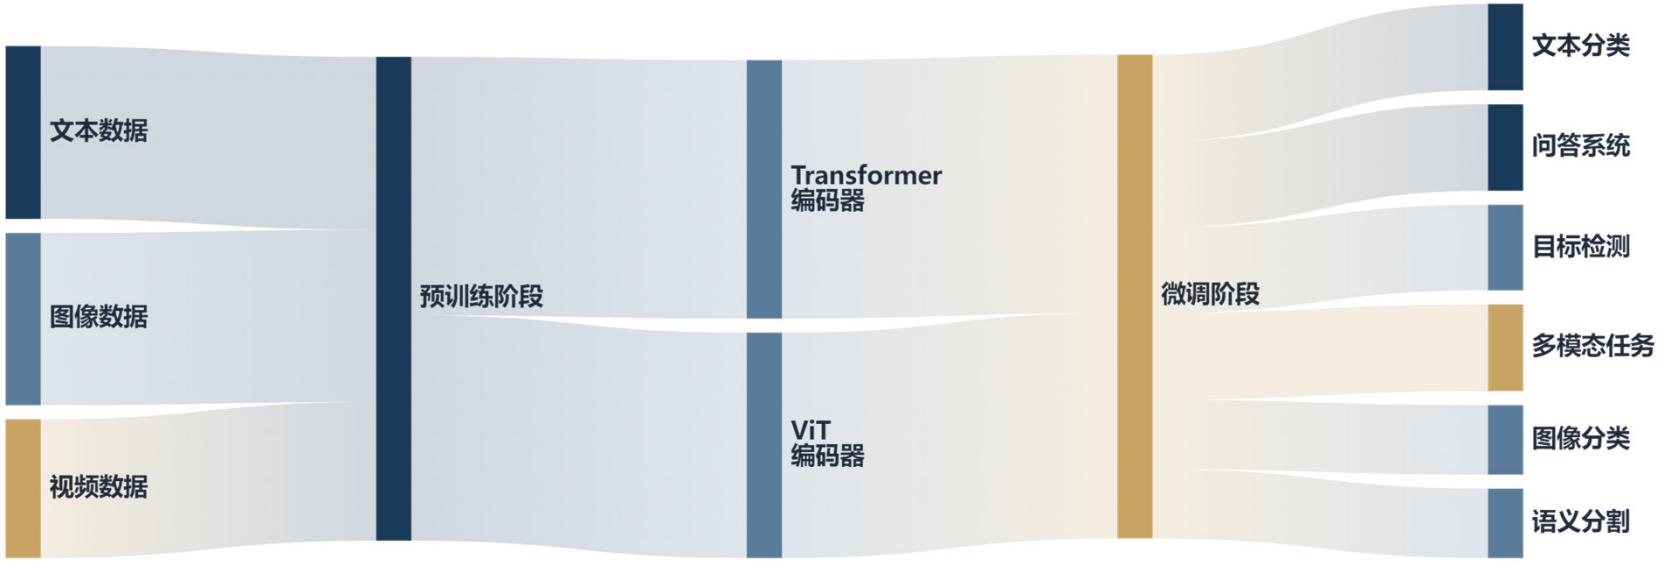

原始数据
文本、图像、视频

编码器
Transformer/ViT

下游任务
分类、检测、问答

为什么多模态需要预训练？

Special Challenges in Multimodal Scenarios

表示空间差异

文本、图像、语音的表示空间不同

- 文本：离散的符号序列，语义抽象
- 图像：连续的像素矩阵，视觉特征
- 语音：时频信号，声学特征

标注成本极高

标注图文对/视频文本对成本极高

- 需要人工配对不同模态的数据
- 标注者需要理解多模态内容
- 标注量需求大，成本呈指数增长

跨模态对齐

需要学习跨模态的语义对应

- 同一概念在不同模态中的表达差异大
- 需要建立统一的语义嵌入空间
- 对齐质量直接影响下游任务性能

预训练的解决方案

预训练可自动学习跨模态关联

- 利用对比学习自动对齐图文
- 从海量无标注数据中学习
- 建立统一的跨模态表示空间

小结：预训练的核心价值

Summary: The Core Value of Pre-training

提供强大的初始化

预训练模型为下游任务提供了优质的初始参数，避免了从零开始的随机初始化，大幅缩短训练时间，提高模型收敛稳定性

学习通用的特征表示

从海量数据中学习到的通用表示捕捉了数据的底层结构与高层语义，这些特征可迁移到各种下游任务，实现知识复用

减少对标注数据的依赖

通过自监督预训练，模型可以从无标注数据中学习，微调阶段只需少量标注数据即可达到优异效果，降低标注成本10-100倍

为多模态融合奠定基础

预训练建立了统一的跨模态表示空间，使文本、图像、语音等不同模态能够在同一语义空间中对齐与融合

预训练是大模型能力的基石，自监督学习是突破标注瓶颈的关键

NLP预训练任务概览

Overview of NLP Pre-training Tasks

MLM
掩码语言模型

Masked Language Modeling

随机遮蔽词，让模型补全

DAE
去噪自编码器

Denoising Autoencoder

破坏输入，重构原文

RTD
字符替换检测

Replaced Token Detection

判别任务替代生成

NSP
下一句预测

Next Sentence Prediction

句子级关系建模

SOP
句子顺序预测

Sentence Order Prediction

NSP的改进版本

核心观点：从词预测到句子关系建模

词级任务

MLM、RTD关注词汇级别的预测与判别

句子级任务

NSP、SOP学习句子间的关系与连贯性

序列级任务

DAE关注整个序列的重构与去噪

MLM：掩码语言模型（概念）

Masked Language Modeling

核心思想

随机遮蔽输入句子中的部分词汇，让模型根据上下文预测被遮蔽的词，从而实现**双向上下文理解**

与从左到右的语言模型不同，MLM可以同时利用被遮蔽词左右两侧的上下文信息进行预测

实现步骤

1. **随机选择Token**
   在输入句子中随机选择约15%的Token作为遮蔽目标
2. **用[MASK]替换**
   将选中的Token替换为特殊的[MASK]标记
3. **预测被遮蔽词**
   训练模型根据上下文预测被遮蔽的原始词汇

核心优势

双向上下文

同时利用左右两侧的上下文信息，理解更全面

深度语义理解

被迫理解句子语义才能准确预测缺失词

适合理解任务

在分类、问答等NLU任务上表现优异

代表模型：BERT、RoBERTa、ALBERT等

MLM：示例展示

A Concrete MLM Example

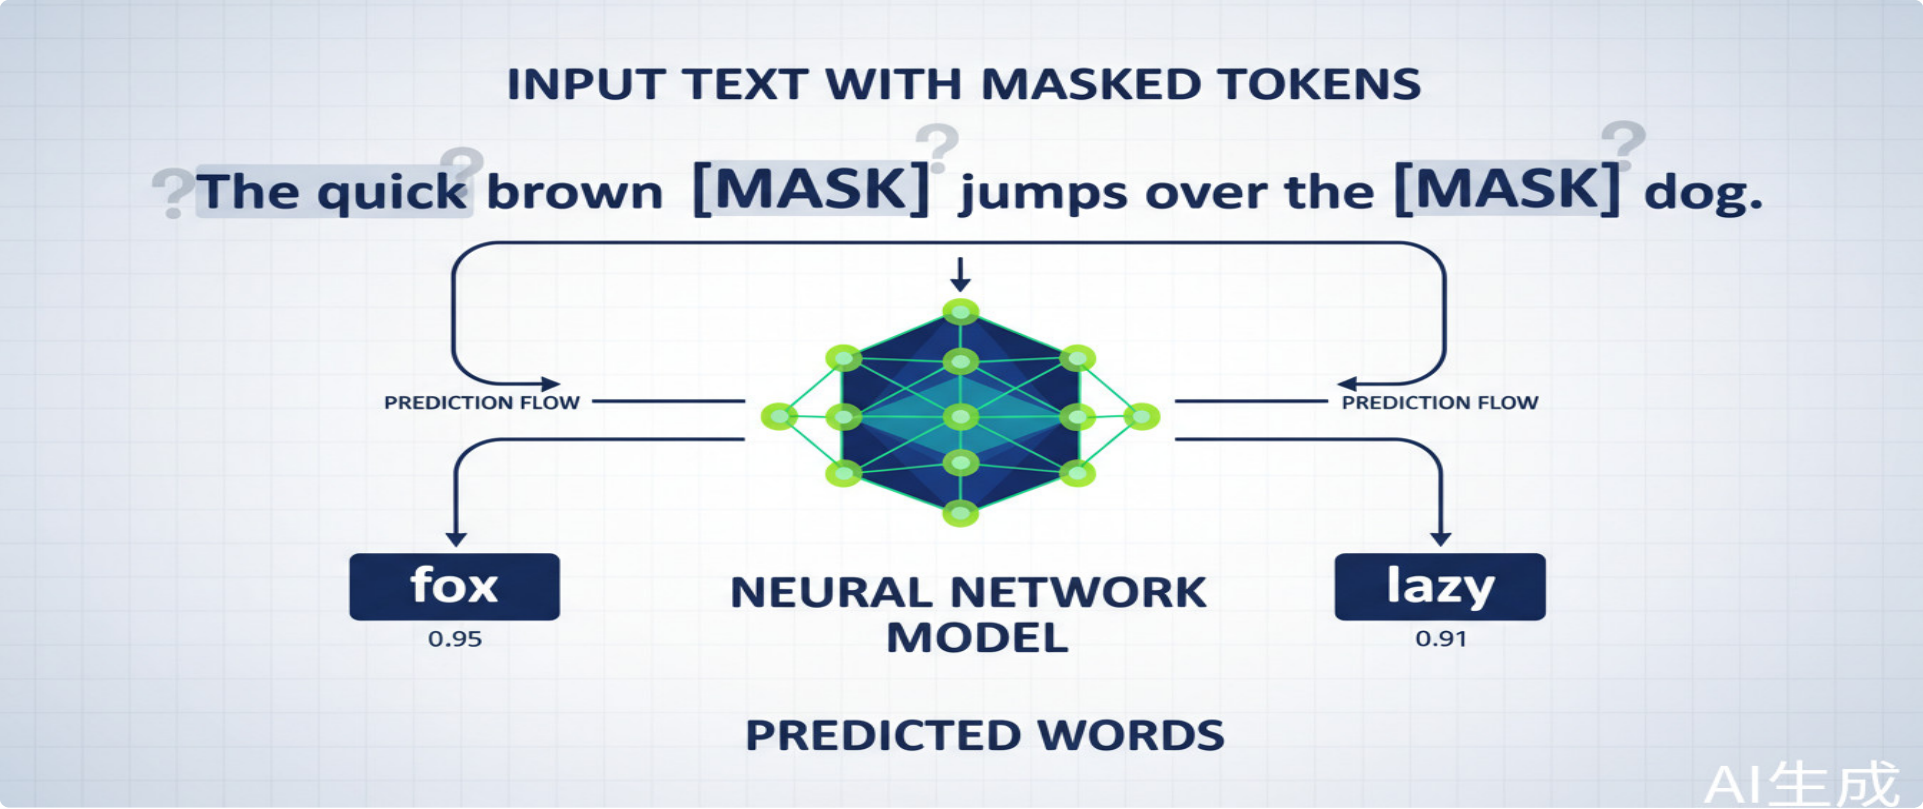

原句
"今天天气很好，我们一起去公园"

遮蔽后
"今天天气很[MASK]，我们一起去公园"

模型预测
"好"（概率最高）

BERT：MLM的代表模型

BERT: Bidirectional Encoder Representations from Transformers

架构特点

多层Transformer Encoder

- 纯Encoder架构，无Decoder
- 双向自注意力机制
- Base版12层，Large版24层

训练数据

BooksCorpus
约8亿词的书籍文本

Wikipedia
约25亿词的百科文章

预训练任务

MLM（掩码语言模型）
遮蔽15%的Token进行预测

NSP（下一句预测）
判断两个句子的连贯性

下游任务

- 文本分类
- 问答系统
- 命名实体识别
- 情感分析

影响力：BERT开启了NLP的预训练时代，被誉为"NLP的ImageNet时刻"

SpanBERT：MLM的改进

SpanBERT: Masking Continuous Token Sequences

核心改进

从单词级掩码扩展到词组级掩码（Span Masking），遮蔽连续的Token序列而非单个词

这种改进更好地建模了短语级语义，对理解多词表达和实体识别尤为重要

实现方式

1. **采样Span长度**
   根据几何分布采样Span长度，偏好较短Span
2. **随机选择起始位置**
   在句子中随机选择Span的起始位置
3. **预测整个Span**
   基于Span边界词的表示预测整个Span

优势与效果

更好的短语级语义建模
学习多词表达和命名实体的完整语义

抽取式问答表现优异
在SQuAD等问答数据集上超越BERT

指代消解能力提升
更好地理解代词与实体的指代关系

核心洞察：Span级别的掩码迫使模型学习更完整的语义单元表示

DAE：去噪自编码器（概念）

Denoising Autoencoder

核心思想

向输入数据添加噪声（删除、打乱、替换等），然后训练模型从带噪声的输入中重构原始数据

通过重构任务，模型被迫学习数据的内在结构和语义信息，从而获得鲁棒的表示能力

噪声类型

- Token删除：随机删除部分Token
- 顺序打乱：打乱Token或句子顺序
- Token替换：用随机Token或[MASK]替换
- 文本填充：用单个[MASK]替换连续Span

核心优势

学习鲁棒的表示

对输入噪声具有更强的容忍度，表示更稳定

更强的句法理解

重构任务需要理解句子结构和语法规则

篇章结构建模

句子顺序预测等任务学习文档级结构

代表模型：BART、T5等Seq2Seq架构模型

BART：DAE的代表模型

BART: Bidirectional and Auto-Regressive Transformers

架构特点

Transformer Seq2Seq架构

- 双向Encoder + 自回归Decoder
- 结合了BERT的双向编码和GPT的自回归生成
- 适合生成任务

噪声类型

- Token Masking
- Token Deletion
- Text Infilling
- Sentence Permutation

擅长任务

文本摘要

将长文档压缩为简短摘要

机器翻译

高质量的跨语言翻译

对话生成

自然流畅的对话回复

核心优势：BART结合了双向理解和自回归生成，是NLG任务的理想选择

DAE的噪声类型示意

BART's Five Types of Noise

Token Masking
随机遮蔽

原始：今天天气很好
噪声：今天[MASK]很好

Token Deletion
随机删除

原始：今天天气很好
噪声：今天很好

Text Infilling
文本填充

原始：今天天气很好
噪声：今天[MASK]

Sentence Permutation
句子打乱

原始：A句。B句。C句。
噪声：B句。C句。A句。

Document Rotation
文档旋转

原始：开头...结尾
噪声：中间...开头

多样化噪声增强鲁棒性：不同类型的噪声迫使模型学习不同层面的语言知识，提升泛化能力

RTD：字符替换检测（概念）

Replaced Token Detection

核心思想

用判别任务替代生成任务，训练模型判断每个Token是否被替换，而非预测原始Token

所有Token都参与训练（而非仅15%的遮蔽Token），计算效率更高，样本利用率更好

实现机制

1. **小Generator替换**
   小型MLM模型生成替换候选
2. **大Discriminator判别**
   主干模型判断每个Token真假
3. **二分类损失**
   使用交叉熵损失训练判别器

核心优势

计算效率更高

所有Token都参与训练，样本利用率100%

性能超越BERT

同等计算量下，RTD性能显著优于MLM

判别vs生成

判别任务通常比生成任务更容易学习

代表模型：ELECTRA

ELECTRA：RTD的代表模型

ELECTRA: Pre-training Text Encoders as Discriminators

架构设计

Generator

小型MLM模型，生成替换Token的候选

Discriminator

主干模型，判断每个Token是否被替换

训练流程

1. **输入原始句子**
   将原始文本输入Generator
2. **Generator生成替换**
   选择部分Token进行替换
3. **Discriminator判别**
   判断每个Token的真假
4. **二分类损失训练**
   使用交叉熵损失优化

性能优势

同等计算量下超越BERT
训练速度更快，效果更好

小模型也能达到好效果
适合资源受限场景

关键洞察：判别式预训练比生成式更高效，所有Token都参与学习

ELECTRA训练流程图

Generator-Discriminator Collaboration

NSP：下一句预测（概念）

Next Sentence Prediction

核心思想

输入两个句子A和B，训练模型判断B是否是A的后续句，学习句子级别的关系建模

通过二分类任务，让模型理解句子间的连贯性和逻辑关系

样本构造

正样本

实际连续的两句话，标签为1（是后续句）

负样本

随机拼接的两句话，标签为0（非后续句）

设计目的

学习句子连贯性

理解段落内句子间的逻辑关系

篇章结构理解

建模文档级别的结构信息

服务下游任务

对句子对分类任务有帮助

代表模型：BERT原始版本

NSP的作用与局限

NSP in BERT: Benefits and Limitations

优点

- ✓ **学习句子间的连贯性**
  帮助模型理解段落结构和句子逻辑
- ✓ **对句子对任务有帮助**
  如自然语言推理、语义相似度计算
- ✓ **引入文档级信息**
  超越句子级别，建模更大粒度

缺点

- ✕ **任务过于简单**
  模型容易通过主题区分而非连贯性
- ✕ **负样本构造简单**
  随机采样导致主题差异明显
- ✕ **可能不是必需的**
  RoBERTa移除NSP后性能提升

后续研究发现

RoBERTa实验

移除NSP任务后，模型在多个下游任务上性能反而提升

ALBERT改进

用SOP（句子顺序预测）替代NSP，任务难度增加，效果更好

核心结论

NSP的原始设计存在问题，需要更精细的任务设计

⚠ 争议：NSP是否必要仍有讨论，但其启发性推动了后续改进

SOP：句子顺序预测（概念）

Sentence Order Prediction

核心思想

SOP是NSP的改进版本，输入同一文档的两个连续片段，判断它们的顺序是否正确

相比NSP，SOP避免了主题泄露问题，任务难度更高，更能有效学习句子间的关系

样本构造

正样本

同一文档的两个连续片段保持原始顺序，标签为1

负样本

交换两个片段的顺序，标签为0

相比NSP的改进

避免主题泄露

正负样本来自同一文档，主题一致，模型必须通过理解句子关系而非主题来区分

任务难度更高

判断顺序比判断是否连续更具挑战性，学习信号更强

效果更好

在多个NLU任务上表现优于NSP

代表模型：ALBERT

ALBERT：SOP的代表模型

ALBERT: A Lite BERT for Self-supervised Learning

创新点

跨层参数共享

所有Transformer层共享同一套参数，大幅减少模型大小

SOP替代NSP

用句子顺序预测替代下一句预测，提升句子级理解

嵌入层分解

将大词汇表嵌入分解为两个较小的矩阵

技术细节

参数共享策略

所有层的注意力参数和前馈网络参数共享

SOP实现

从同一文档采样连续片段，50%概率交换顺序

嵌入分解

$V \times H \rightarrow (V \times E) + (E \times H)$，E远小于H

性能表现

超越BERT

在多个NLU任务上性能更优

参数更少

模型大小减少18倍，训练速度提升1.7倍

核心洞察：通过参数共享和任务改进，ALBERT实现了更小、更快、更强的模型

NLP预训练任务对比表

Comparison of NLP Pre-training Tasks

任务	代表模型	训练信号	擅长能力
MLM	BERT	词级预测	双向理解、词法语义
DAE	BART	序列重构	生成任务、去噪能力
RTD	ELECTRA	判别真假	高效训练、样本利用
NSP	BERT	句对关系	简单关系建模（有争议）
SOP	ALBERT	句顺序	细粒度关系、篇章理解

核心观点：五大任务各有侧重，互为补充，多任务预训练成为主流趋势

NLP预训练的演进时间线

Evolution Timeline: 2018-2023

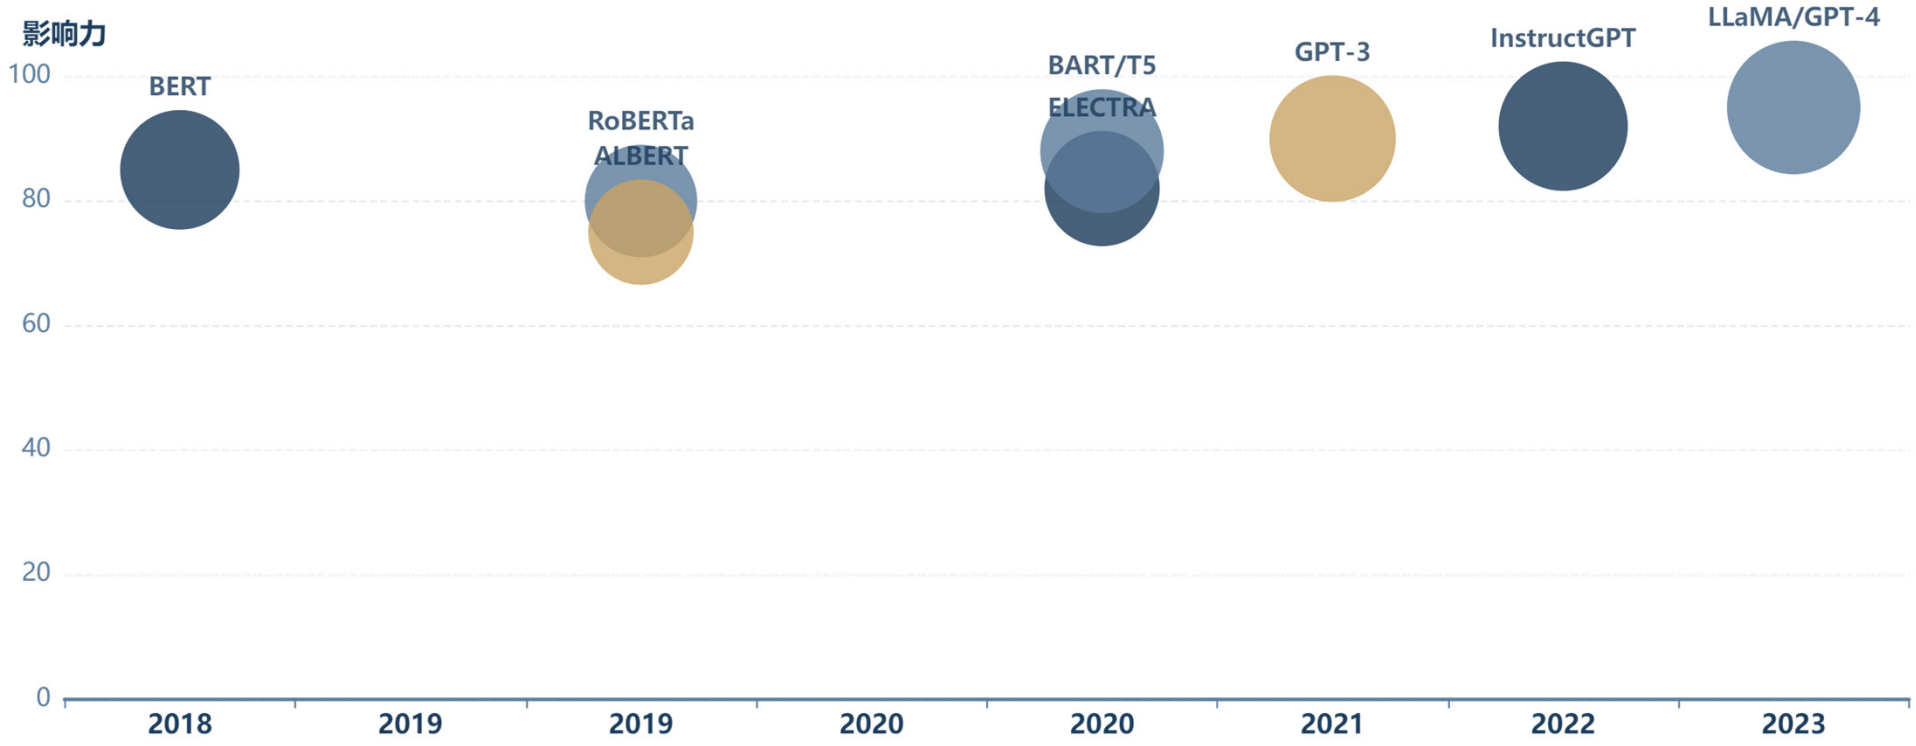

最新进展：指令预训练

Instruction Pre-training

趋势演变

从语言建模到指令理解，预训练任务向指令对齐演化，让模型更好地理解和执行人类指令

通过在预训练阶段引入指令格式数据，模型学会遵循指令、理解上下文、生成有用回复

核心优势

- **更好的指令遵循**
  模型学会理解和执行各种指令
- **多任务能力**
  单个模型处理多种任务类型
- **零样本/少样本能力**
  无需微调即可适应新任务

代表性模型

FLAN-T5

多任务指令预训练，将任务转化为指令格式

InstructGPT

RLHF对齐人类偏好，提升指令遵循能力

LLaMA 2 Chat

Chat版本的指令微调，对话能力突出

趋势：预训练与对齐逐步融合，指令格式成为标准

多语言与跨语言预训练

Multilingual and Cross-lingual Pre-training

全球化趋势

从英文单语到多语言统一表示，预训练模型支持100+语言，实现跨语言理解与迁移

通过共享的词汇表和编码器，不同语言在同一语义空间中表示，实现跨语言零样本迁移

核心优势

- **统一表示空间**
  不同语言共享同一语义空间
- **跨语言迁移**
  低资源语言受益于高资源语言
- **多语言理解**
  单个模型处理多种语言

代表性模型

mBERT

多语言BERT，支持104种语言

XLM-R

跨语言掩码建模，RoBERTa的多语言版本

mT5

多语言T5，101种语言的文本到文本框架

影响：多语言预训练推动了NLP技术的全球化普及

小结：NLP预训练任务的核心思想

Summary: Core Ideas of NLP Pre-training

遮蔽预测

MLM通过遮蔽部分词汇，迫使模型利用上下文进行预测，学习双向语义理解

去噪重构

DAE通过添加噪声并重构原始数据，让模型学习鲁棒的表示和序列生成能力

判别真假

RTD通过判别任务替代生成任务，提高训练效率，所有Token都参与学习

学习层次

- 词法：词汇含义、词性标注
- 句法：句子结构、语法关系
- 语义：词义理解、语义角色
- 篇章：文档结构、连贯性

发展趋势

→ 多任务预训练成为主流

→ 指令对齐逐步融合

→ 多语言统一表示空间

→ 自监督信号来自文本本身

★ 自监督信号来自文本本身，为下游NLU和NLG任务提供坚实基础

CV预训练任务概览

Overview of CV Pre-training Tasks

特定代理任务

拼图
旋转
上色
修补

帧序学习

视频预测
帧序判断
时序建模
CPC

数据生成

GAN
VAE
生成器
判别器

数据重建

MIM
MAE
BEiT
掩码建模

对比学习

SimCLR
MoCo
聚类
DINO

核心观点：从代理任务到自监督学习，CV预训练经历了从人工设计到自动学习的转变

为什么CV需要预训练？

Why Does CV Need Pre-training?

标注挑战

ImageNet标注耗时数年

120万张图片，1000个类别，人工标注工作量巨大

分割任务逐像素标注

语义分割、实例分割需要像素级标注，成本极高

3D场景理解复杂

深度估计、3D检测需要专业设备和知识

成本问题

标注成本高昂

单张图片标注费用从几美分到数美元不等

需要专业人员

医学图像、工业检测需要领域专家

自监督的解决方案

利用海量无标注图像

互联网上有数十亿张无标注图片可供预训练使用

自动学习视觉特征

通过代理任务自动提取有用的视觉表示

降低下游任务标注需求

预训练后只需少量标注数据即可微调

关键洞察：自监督预训练让CV模型突破标注瓶颈，实现数据高效学习

特定代理任务：图像修补

Inpainting as Pre-training Task

核心思想

随机遮蔽图像中心区域，训练模型补全缺失部分，需要理解图像整体语义才能准确重构

图像修补迫使模型学习上下文信息和语义理解，而非简单的纹理复制

实现方式

1. **选择遮蔽区域**
   通常选择图像中心区域（如128×128）
2. **生成掩码**
   创建二值掩码标记遮蔽区域
3. **重构损失**
   像素级损失 + 感知损失

核心优势

语义理解

需要理解图像整体语义才能准确补全

上下文学习

学习利用周围像素推断缺失区域

可迁移性

学到的特征可迁移到检测、分割任务

应用：Context Encoder等模型使用Inpainting进行预训练

图像修补示意图

Inpainting Visualization

原图

完整的风景照

遮蔽图

中间区域抠空

重构图

模型补全结果

评估指标

像素级损失

L1/L2损失衡量像素差异

感知损失

使用预训练网络提取特征差异

特定代理任务：Colorization

Image Colorization as Pre-training Task

核心思想

将灰度图作为输入，训练模型预测彩色图的ab通道，需要理解物体语义才能准确上色

颜色预测任务迫使模型学习物体的语义类别和常见颜色分布

实现方式

输入：灰度图（L通道）
从RGB转换到Lab颜色空间，提取L通道

输出：彩色图（ab通道）
预测ab通道，与L通道组合得到彩色图

损失函数
回归损失（L1/L2）或分类损失

核心优势

语义理解

需要理解物体类别才能预测正确颜色（天空蓝、草地绿）

正迁移效果

学到的特征对下游分类任务有显著帮助

数据丰富

任何彩色图像都可以转换为训练数据

代表工作：Colorful Image Colorization (Zhang et al., 2016)

Colorization示例

Colorization Examples

人物照片上色

输入：黑白照片

输出：彩色照片

风景照片上色

输入：黑白照片

输出：彩色照片

模型学习到的知识

- 天空 → 蓝色
- 草地 → 绿色
- 阳光 → 黄色
- 皮肤 → 肤色

特定代理任务：RotNet

Rotation Prediction

核心思想

将图像旋转0°/90°/180°/270°，训练模型预测旋转角度（4分类任务），学习物体的方向和结构

简单但极其有效的自监督信号，模型必须理解物体的几何结构才能正确判断旋转角度

实现方式

1. **随机旋转**
   将图像随机旋转0°、90°、180°或270°
2. **4分类任务**
   训练模型预测旋转角度（4类）
3. **交叉熵损失**
   使用分类损失进行训练

惊人效果

接近监督学习

在ImageNet分类上，RotNet预训练效果接近监督预训练

简单有效

无需复杂设计，旋转预测即可学到强大特征

几何结构学习

模型学习到物体的方向、对称性等几何属性

代表工作：RotNet (Gidaris et al., 2018)

RotNet示意图

Rotation Prediction Visualization

0°

原始方向

90°

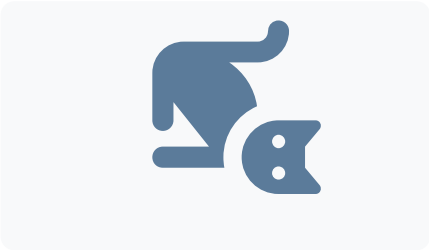

顺时针90°

180°

旋转180°

270°

顺时针270°

模型输出示例

0°

概率: 85%

90°

概率: 5%

180°

概率: 7%

270°

概率: 3%

特定代理任务：Jigsaw拼图

Jigsaw Puzzle as Pre-training Task

核心思想

将图像切成9块（3×3），随机打乱顺序，训练模型预测正确排列（9! = 362,880种可能）

拼图任务迫使模型学习局部和全局的空间关系，理解物体的拓扑结构

实现方式

1. **切分图像**
   将图像均匀切成3×3的9个Patch
2. **随机打乱**
   随机排列9个Patch的顺序
3. **预测排列**
   预测正确的排列索引（9!分类）

核心优势

空间关系建模

学习局部Patch之间的相对位置关系

拓扑结构理解

理解物体的整体结构和部件关系

全局上下文

需要理解图像全局信息才能正确拼图

代表工作：Jigsaw Puzzle (Noroozi & Favaro, 2016)

Jigsaw示意图

Jigsaw Puzzle Visualization

原图

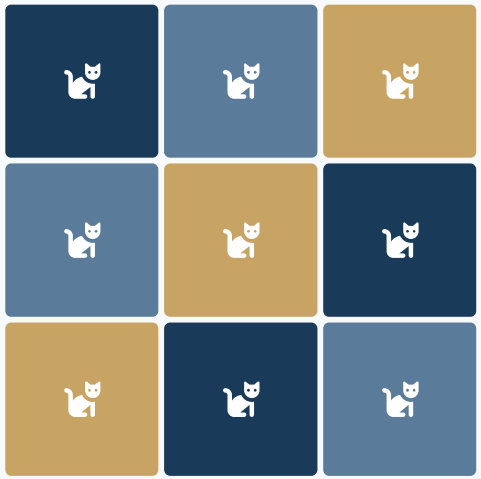

打乱图

任务挑战

362,880
9!种可能的排列组合

3×3
标准切分网格大小

分类
预测正确的排列索引

Jigsaw的改进：CDJP

Completing Damaged Jigsaw Puzzles

核心改进

在拼图任务基础上增加难度：拼图缺少一块（8块可见），每块包含不完整的颜色信息

同时解决拼图和补全任务，迫使模型学习更鲁棒的视觉表示

双重挑战

挑战1：拼图任务

确定8块可见Patch的正确排列位置

挑战2：补全任务

补全缺失的第9块Patch

额外难度

每块Patch的颜色信息不完整

优势

更鲁棒的表示

面对不完整信息仍能正确推理

更强的语义理解

需要更深层次的语义理解才能完成任务

性能提升

在下游任务上表现优于标准Jigsaw

核心洞察：增加任务难度可以学到更鲁棒的特征表示

特定代理任务：视觉基元计数

Counting Visual Primitives

核心思想

计算图像中的视觉基元（线条、角点、对称轴等），需要对图像进行抽象理解的高层语义任务

超越简单的像素级任务，迫使模型学习对图像进行抽象和推理

视觉基元类型

- 线条：直线、曲线、边缘
- 角点：拐角、交点
- 对称轴：镜像对称线
- 形状：基本几何形状

核心优势

高层语义理解

需要对图像进行抽象和概念化理解

超越SOTA

超越了当时其他代理任务的效果

推理能力

培养模型的抽象推理能力

代表工作：Noroozi et al., 2017

特定代理任务小结

Summary of Pretext Tasks

设计原则

任务应足够难

避免捷径解，迫使模型学习深层特征

与下游任务相关

代理任务应与目标任务语义相关

多样化任务

学习不同方面

不同任务学习不同视觉特征

组合效果更好

多个任务联合训练效果更佳

代理任务对比

Inpainting	Colorization	RotNet	Jigsaw	Counting
语义理解	颜色学习	几何结构	空间关系	抽象推理

核心洞察：好的代理任务应该既足够困难以避免捷径解，又与下游任务语义相关

帧序学习任务：视频预测

Video Prediction

核心思想

从视频中学习**时序表示**，任务是预测下一帧或前几帧，需要理解运动、因果关系

视频提供了时间维度的自监督信号，让模型学习动态变化和时序逻辑

实现方式

1. **输入历史帧**
   输入连续的若干帧视频
2. **预测未来帧**
   预测下一帧或未来几帧
3. **像素级损失**
   使用L1/L2损失优化

核心优势

运动理解

学习物体的运动模式和速度

因果关系

理解事件的因果逻辑

可迁移性

对动作识别、视频理解有效

代表方法：CPC (Contrastive Predictive Coding)

帧序学习任务：帧序判断

Frame Order Verification

核心思想

判断视频**帧序是否正确**，正样本是原始帧序，负样本是打乱帧序，学习事件的时间逻辑

相比帧预测，帧序判断是判别任务，可能更容易学习

样本构造

正样本

原始帧序，标签为1（顺序正确）

负样本

打乱帧序，标签为0（顺序错误）

核心优势

时间逻辑

学习事件的时间顺序和逻辑关系

因果推理

理解动作的因果关系

视频理解

对视频分类、动作识别有帮助

应用：视频理解、动作识别、时序建模

CPC：对比预测编码

Contrastive Predictive Coding

核心思想

编码历史信息为上下文向量，预测未来时刻的表示，用对比损失区分正样本和负样本

CPC是一种通用的自监督学习框架，适用于音频、视频、文本等多种模态

实现步骤

1. **编码历史**
   用编码器提取历史信息特征
2. **自回归建模**
   用自回归模型预测未来表示
3. **对比损失**
   拉近正样本，推远负样本

核心优势

通用框架

适用于音频、视频、文本等多种模态

学习时序依赖

有效建模时间序列的依赖关系

性能优异

在多个任务上取得SOTA效果

代表工作：CPC (van den Oord et al., 2018)

CPC示意图

CPC Architecture Visualization

时间序列
帧序列/音频

编码器
CNN/RNN

自回归模型
GRU/LSTM

对比损失
InfoNCE

步骤1：特征提取
编码器提取历史帧的特征表示

步骤2：未来预测
自回归模型预测未来帧的表示

步骤3：对比学习
拉近正样本，推远负样本

数据生成任务：GAN与VAE

Generative Models as Pre-training

核心思想

通过生成过程学习数据的内在表示，生成质量与表示质量正相关

生成模型的编码器/判别器可以提取有用的特征用于下游任务

GAN

判别器学习

判别器学习区分真假图像的特征

特征提取

判别器中间层特征可用于下游任务

VAE

Encoder学习

Encoder学习紧凑的潜在表示

Decoder重构

Decoder从潜在表示重构图像

可迁移性

Encoder学到的特征可迁移到判别任务

核心洞察：生成与表示学习相辅相成

BigBiGAN：生成模型预训练

Large-scale GAN Pre-training

架构设计

联合训练生成器和编码器，判别器区分真实图像和重构图像

BigBiGAN将GAN与表示学习结合，编码器学到的特征在下游任务上表现优异

核心组件

Generator
从潜在向量生成图像

Encoder
将图像编码为潜在向量

Discriminator
区分真实与生成样本

性能表现

接近监督学习
在ImageNet分类上接近监督预训练效果

高质量表示
编码器学到语义丰富的特征表示

可迁移性
特征可迁移到分类、检测等任务

代表工作：BigBiGAN (Donahue & Simonyan, 2019)

数据重建任务：掩码图像建模

Masked Image Modeling (MIM)

核心思想

CV版本的BERT，将图像划分为Patch，随机遮蔽部分Patch，训练模型预测被遮蔽Patch

MIM让模型学习全局语义表示，理解图像的整体结构和上下文关系

实现方式

1. **划分Patch**
   将图像划分为16×16的Patch
2. **随机遮蔽**
   随机遮蔽75%的Patch
3. **预测重构**
   预测被遮蔽Patch的像素值

核心优势

全局语义
学习图像的全局语义表示

上下文理解
理解Patch之间的上下文关系

可迁移性
特征可迁移到分类、检测、分割

代表模型：MAE、BEiT

MAE：Masked Autoencoder

MAE: Masked Autoencoders Are Scalable Vision Learners

核心创新

非对称编解码器：编码器仅处理可见Patch，解码器轻量级重构完整图像

MAE采用高达75%的遮蔽率，在ImageNet上超越监督预训练

架构设计

编码器

ViT架构，仅处理可见Patch（25%）

解码器

轻量级Transformer，重构完整图像

核心优势

高遮蔽率

75%遮蔽率，避免简单纹理复制

训练效率

只编码25%Patch，速度提升3倍

性能优异

超越监督预训练，SOTA效果

代表工作：MAE (He et al., 2021)

MAE示意图

MAE Workflow

输入图像
224×224

→

划分Patch
14×14=196

→

随机遮蔽
75%=147

→

编码器
处理49个

→

解码器
重构196个

输入
196个Patch（14×14网格）

可见
49个Patch（25%）送入编码器

重构
196个Patch（100%）解码器输出

MAE的优势

Why MAE Works

语义理解

高遮蔽率避免简单的纹理补全，模型必须理解图像的语义结构才能准确重构

表示有效

学到的表示对分类、检测、分割等多种任务都有效

训练效率

只编码25% Patch，训练速度提升3倍，大幅降低计算成本

核心洞察

MAE的成功证明了高遮蔽率 + 非对称编解码器是视觉自监督学习的有效范式

BEiT：BERT式的图像预训练

BEiT: BERT Pre-training of Image Transformers

核心思想

用DALL-E的dVAE将Patch离散化为视觉Token，类似BERT的掩码预测

BEiT将图像视为"视觉句子"，Patch视为"视觉词汇"，实现BERT式的预训练

实现方式

步骤1：Token化

用dVAE将Patch映射为离散Token

步骤2：掩码预测

遮蔽部分Patch，预测离散Token

核心优势

BERT范式迁移

将NLP的BERT范式成功迁移到CV

语义建模

离散Token更好地建模语义信息

性能优异

在多个下游任务上表现优异

代表工作：BEiT (Bao et al., 2021)

对比学习与聚类：引言

From Pretext Tasks to Contrastive Learning

范式转变

从人工设计标签到自动生成正负样本，对比学习实现了实例判别的范式转变

核心思想：同一实体的不同增强视图是正样本，不同实体是负样本

核心思想

正样本

同一实体的不同数据增强视图

负样本

不同实体的所有视图

优势

自动生成标签

无需人工设计代理任务

性能优异

接近甚至超越监督学习

通用框架

适用于多种数据模态

代表方法：SimCLR、MoCo、SwAV

对比学习的基本框架

Basic Framework of Contrastive Learning

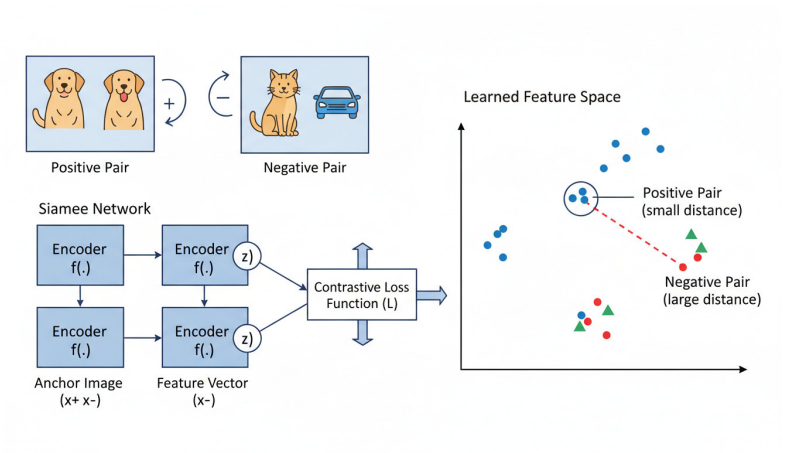

输入

一张图像

数据增强

生成两个视图v1、v2

编码器

提取特征f1、f2

对比损失

拉近正样本，推远负样本

SimCLR：简单的对比学习

SimCLR: A Simple Framework for Contrastive Learning

架构设计

双流编码器

两个相同的编码器（权重共享）

投影头

MLP将特征映射到对比空间

关键要素

大Batch

4096或8192，提供更多负样本

强数据增强

裁剪、颜色抖动、高斯模糊

核心优势

简单有效

无需记忆库，直接端到端训练

性能优异

在ImageNet上接近监督学习

NT-Xent损失

归一化温度缩放交叉熵损失

代表工作：SimCLR (Chen et al., 2020)

SimCLR示意图

SimCLR Pipeline

数据增强

随机裁剪、颜色抖动、高斯模糊

编码器

ResNet或ViT提取特征

投影头

2层MLP映射到对比空间

MoCo：动量对比学习

Momentum Contrast for Unsupervised Visual Representation Learning

核心创新

记忆池 + 动量编码器，维护一个大的特征队列，小Batch也能有大量负样本

MoCo解决了对比学习需要大Batch的问题，用记忆池提供大量负样本

核心组件

查询编码器

正常梯度更新

键编码器

动量更新（缓慢变化）

记忆队列

存储历史特征作为负样本

核心优势

小Batch友好

256的Batch也能有大量负样本

动量更新

保持特征一致性，稳定训练

性能优异

在多个任务上超越监督学习

代表工作：MoCo (He et al., 2020)

MoCo示意图

MoCo Queue Mechanism

查询q
当前Batch的增强

键k
队列中的历史特征

队列机制（FIFO）

入队
当前Batch特征入队

队列
存储K个历史特征

出队
最老的特征出队

正样本
q与k+（同一张图像的增强）对比

负样本
q与队列中其他k对比

SimCLR vs MoCo

Comparison of Contrastive Learning Frameworks

维度	SimCLR	MoCo
负样本来源	当前Batch	记忆队列
Batch要求	大（4096+）	小（256）
编码器	权重共享	动量更新
计算开销	高	中
效果	略优	相当

核心洞察：大Batch vs 记忆池，两种策略各有优势，效果相当

DeepCluster：聚类驱动预训练

Clustering as Supervisory Signal

核心思想

将聚类作为监督信号，迭代进行特征提取、聚类、训练的过程

通过聚类生成伪标签，用伪标签训练模型，特征逐渐语义化

迭代流程

1. **特征提取**
   用当前模型提取所有图像特征
2. **K-Means聚类**
   得到伪标签
3. **用伪标签训练**
   训练分类模型

核心优势

特征语义化
伪标签逐渐接近真实语义

可迁移性
特征可迁移到分类任务

迭代优化
特征质量随迭代提升

代表工作：DeepCluster (Caron et al., 2018)

DeepCluster流程图

DeepCluster Pipeline

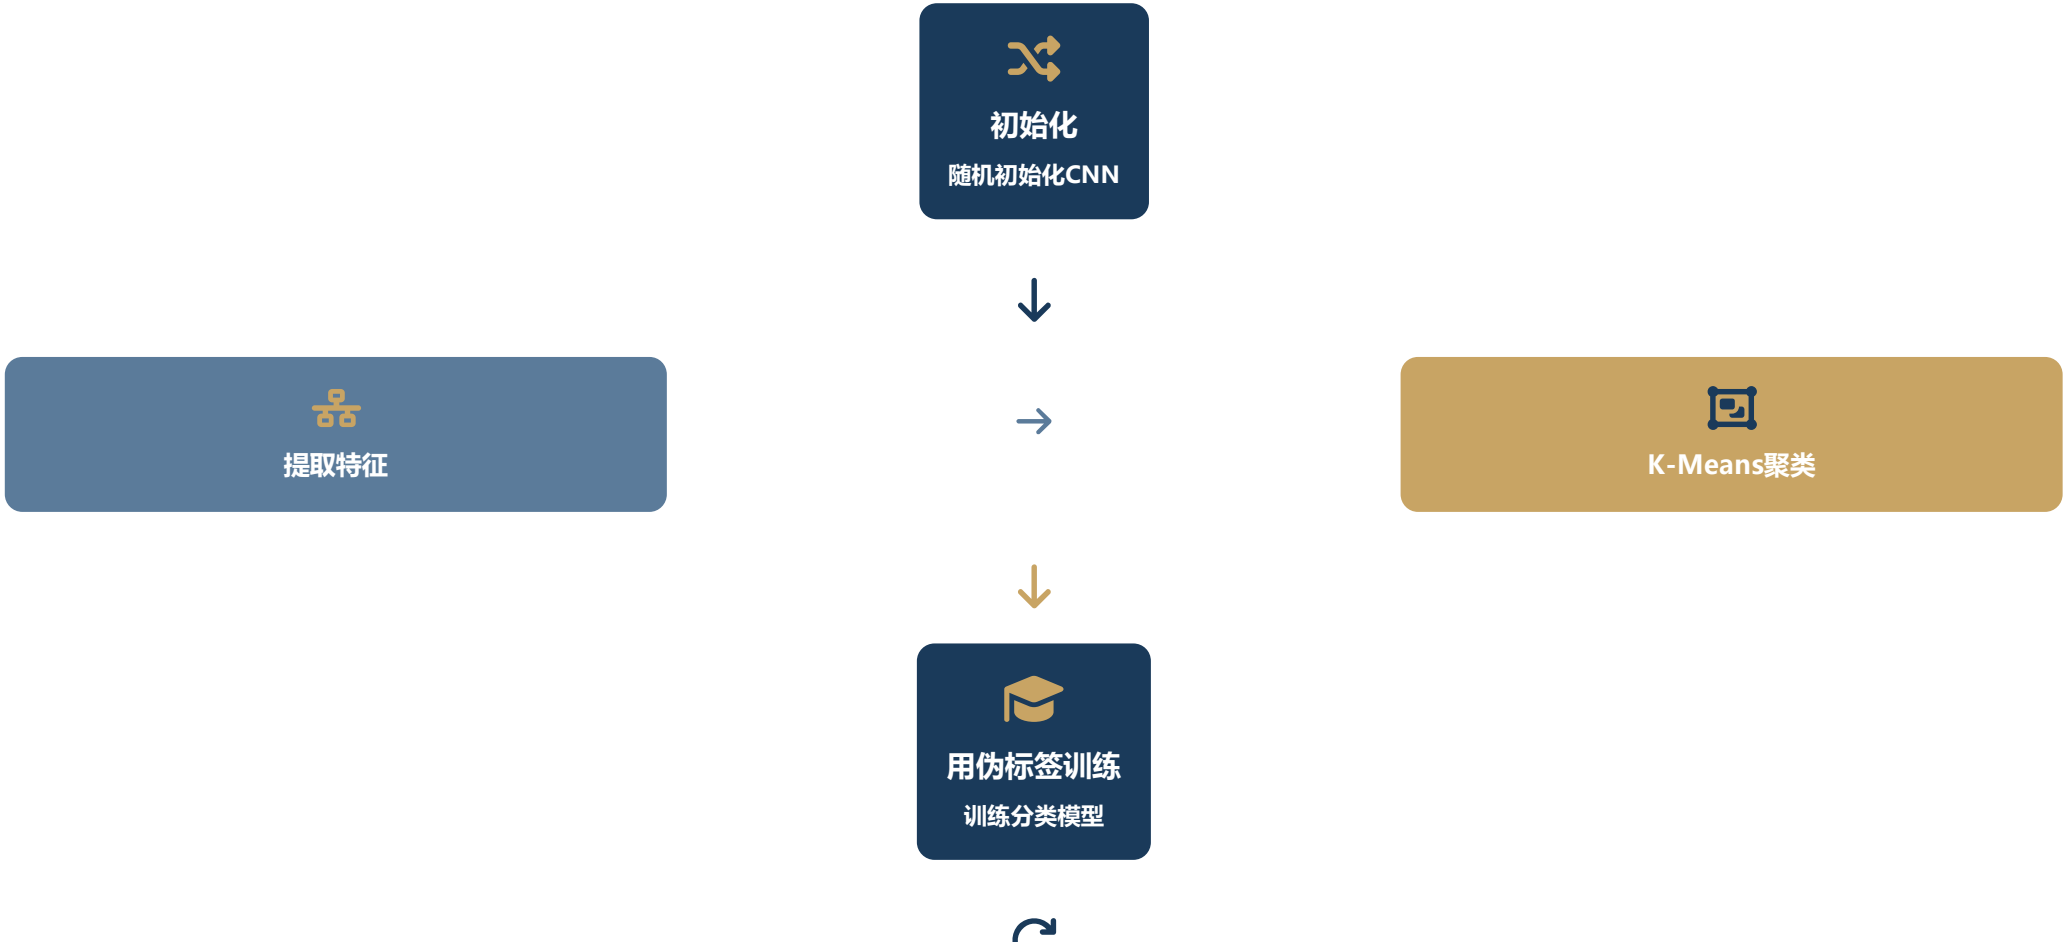

对比学习在CV中的最新进展

Latest Advances in Contrastive Learning (2023-2026)

发展趋势

从单模态到多模态对比，对比学习不断演进，与Transformer架构深度融合

SwAV

原型对比学习，将特征与原型（prototypes）对齐，实现在线聚类

DINO

自蒸馏的对比学习，无需负样本，学生网络学习教师网络的输出，教师网络由学生网络动量更新

CLIP

跨模态对比学习（下一讲重点），将图像和文本映射到统一语义空间

BYOL

无负样本的对比学习，只使用正样本对，通过预测另一个视图的表示来学习

核心洞察：对比学习持续演进，从单模态到多模态，从有负样本到无负样本

小结：CV预训练任务的核心思想

Summary: Core Ideas of CV Pre-training

代理任务

拼图、旋转

上色、修补

掩码重建

MAE、BEiT

高遮蔽率

对比学习

SimCLR、MoCo

拉近正样本

聚类预训练

DeepCluster

SwAV

核心观点

自监督信号

来自图像本身的结构和语义

多样化方法

代理任务、掩码重建、对比学习

→ 下一讲深入对比学习框架

多模态预训练的动机

Motivation for Multimodal Pre-training

挑战1

单模态表示无法对齐：文本、图像、语音的表示空间不同，需要学习跨模态的语义映射

挑战2

标注图文对数据量有限：高质量图文对标注成本极高，预训练可自动学习对齐

解决方案

- 预训练可自动学习跨模态关联
- 对比学习实现图文对齐
- 建立统一的跨模态表示空间

核心洞察：跨模态对齐是多模态预训练的核心目标

跨模态对比学习：CLIP

CLIP: Contrastive Language-Image Pre-training

核心思想

用4亿图文对进行对比学习，将图像和文本映射到统一语义空间

CLIP通过对比损失让匹配的图文对靠近，不匹配的远离

架构设计

图像编码器

ViT或ResNet提取图像特征

文本编码器

Transformer提取文本特征

核心优势

统一语义空间

图文在同一空间中表示

零样本能力

无需微调即可分类

强大泛化

在多个数据集上表现优异

代表工作：CLIP (Radford et al., 2021)

CLIP架构示意图

CLIP Architecture

图像编码器

ViT / ResNet

相似度矩阵

N×N

对角线：正样本
非对角线：负样本

文本编码器

Transformer

图像特征

$I_1, I_2, \ldots, I_n$

文本特征

$T_1, T_2, \ldots, T_n$

预告下一讲

Next Lecture Preview

第2讲：深入对比学习与聚类

我们将深入探讨对比学习的核心机制，详解MoCo、SimCLR、PIRL、LA等经典方法，以及DeepCluster、SwAV、PCL等聚类驱动框架

预习内容

- 教材 2.4-2.4.6 节
- 对比学习经典论文
- 聚类预训练方法

主要内容

- 记忆池与动量编码器
- MoCo、SimCLR、PIRL、LA详解
- DeepCluster、SwAV、PCL框架
- 对比学习在多模态中的应用

请大家预习教材 2.4-2.4.6 节，为下一讲做好准备

问题和讨论