



《多模态大模型原理与应用》

Lecture 12

具身世界模型

刘阳

中山大学

人机物智能融合实验室 (HCP Lab)

liuy856@mail.sysu.edu.cn



| 为什么具身智能需要"先想后做"

● 核心问题

具身智能面对真实世界的动态交互，单靠**反应式控制**难以处理：

- 长时任务规划
- 风险决策与后果评估
- 复杂物理交互预测

● 解决思路

需要能够**预测未来状态**的模型来辅助规划与控制：

- 提前模拟动作后果
- 选择最优行动方案
- 避免危险操作

对比示意



直接抓取（失败）

观察 → 立即动作

不考虑物体滑动、碰撞



先预测再抓取（成功）

观察 → 预测未来 → 规划动作

预判物体运动，调整抓取策略

| 从传统机器人到具身基础模型



 **研究趋势：** 将世界模型嵌入策略，使机器人从"反应式"走向"预测式" —— 这是具身智能的关键范式转变。

| 世界模型的两种核心理解



理解世界

Understanding World

核心目标：构建内部表征去理解世界

学习紧凑、抽象的隐变量表示，抓住环境中对决策有用的结构

关注"世界是什么样的"

预测未来

Predicting Future

核心目标：预测未来状态去支持模拟、规划和决策

从当前观察出发预测未来状态，生成后续帧或未来轨迹

关注"世界会怎样变化"

| 人类直觉类比：快思考与慢思考

系统一：快思考

本能反应，快速自动
不显式依赖世界模型
如：手碰到热物立即缩回

系统二：慢思考

审慎推理，模拟未来
显式依赖世界模型
如：规划如何稳定地搬运杯子

对应到机器人系统

Reactive：感知 → 直接动作
反射式控制

Predictive：感知 → 预测 → 动作
世界模型驱动的规划

| 最低限度直觉：什么是具身世界模型

世界模型

= 环境变化的预测器


预测"如果我做了X，世界会变成什么样"

具身世界模型

= 预测 + 动作生成

既预测环境如何变，又根据未来来产生动作

核心链路



关键：动作不是由当前观察**直接**决定，而是由对未来状态的**预测**来指导

| 具身场景为什么更难

具身任务的世界建模必须兼顾**空间、时间和动作因果关系**，挑战包括：

接触与力

物理接触产生力和反作用力，需要建模力觉反馈

遮挡与形变

物体可能被遮挡，柔性物体会形变，增加预测难度

视角变化

机器人运动时视角不断变化，需要不变的表征

本体差异

不同机器人形态差异大，模型需要跨本体泛化

时序依赖

动作效果随时间展开，需要建模长时动态

因果耦合

动作与观测强耦合，需要建模动作-观测因果链

| 典型任务：抓取、导航、双臂与人形



机械臂操作

抓取、放置、推物、装配等桌面操作任务

核心：理解"我做了什么，物体位置/姿态怎样变"



移动导航

室内/室外路径规划、避障、目标导向移动

核心：预判地形变化和障碍物运动



双臂协调

双手配合完成复杂操作，如折叠衣物、拧瓶盖

核心：协调两臂动作预测各自及联合效果



人形控制

全身运动控制、平衡维持、动态行走

核心：预测身体姿态变化与接触力

| 为什么只做 Observation-to-Action 不够

VLA

观察 (Observation) → 动作 (Action)

- ✗ 不显式建模动作后的物理世界演化
- ✗ 需要前瞻推理时受限
- ✗ 难以处理长时序后果评估

WAM

观察 → 未来预测 → 动作

- ✓ 显式建模世界动态变化
- ✓ 支持前瞻物理推理
- ✓ 可评估动作后果

关键区别： VLA 学习 "看完就动" 的映射，WAM 学习 "看完再想，想完再动" 的闭环

| 核心判断标准：模型是否真的在“想未来”

❓ 分析各种方法时，始终问一个问题：**这个模型是在直接输出动作，还是在借助对未来世界的预测来决定动作？**

Reactive 反应式

- ✗ 直接输出动作
- ✗ 不显式预测未来
- ✗ 仅依赖当前观察

代表：传统VLA、端到端策略

Predictive 预测式

- ✓ 显式或隐式预测未来
- ✓ 基于预测生成动作
- ✓ 动作与未来状态耦合

代表：WAM、World Model + Policy

| 世界模型研究为什么突然变热

近年多模态大模型和视频生成模型的突破，让"用生成模型做世界模拟器"成为更现实的方向：



多模态大模型

GPT-4V等模型提升视觉-语言理解能力，为跨模态世界建模奠定基础



视频生成模型

Sora等模型展现强时空建模能力，接近"未来世界演化"表征



视频理解模型

V-JEPA等模型证明抽象预测可服务世界建模和控制



关键趋势：视频生成模型天然接近"未来世界演化"的表征，使"用生成模型做世界模拟器"从理论走向实践。机器人操作、自动驾驶等领域开始大规模应用世界模型。

| 视频生成为什么推动了世界模型

视频生成模型擅长建模**时空连续变化**，天然接近"未来世界演化"的表征：



时序建模能力：学习帧与帧之间的连续变化规律



空间一致性：保持物体位置、外观的跨帧一致



物理直觉：隐式学习到部分物理规律（重力、碰撞）



条件生成：支持动作/文本条件控制视频生成

因此，很多新世界模型直接借力视频基础模型（如Sora、VDM、LVDM）作为骨干架构，在其上增加动作条件化和物理约束。

| 但视频生成不等于真正的世界模型

✓ 视频生成能做到

- ✓ 强视觉一致性
- ✓ 一定的物理直觉
- ✓ 流畅的时序过渡

✗ 视频生成做不到

- ✗ 精确的因果交互建模
- ✗ 严格的物理规律遵循
- ✗ 动作条件的可靠响应

💡 核心区别

视频生成模型优化的是**视觉逼真度**，而世界模型需要的是**物理正确性和动作可控性**。Sora可以生成逼真的杯子掉落视频，但无法保证杯子遵循正确的重力加速度或响应特定的推力条件。

| 世界模型与模拟器的关系

物理模拟器

特点:

- 显式、外部、可控
- 基于牛顿物理方程
- 精确但计算昂贵

代表: MuJoCo, Isaac Sim, Gazebo

世界模型 (学习式)

特点:

- 数据驱动、内部、可学习
- 从经验中学习动力学
- 高效但可能不精确

代表: RSSM, Transformer WM

互补关系, 非替代

本节内容

CONTENTS

- 一、世界模型基础概念
- 二、世界动作模型的定义、分类与核心架构
- 三、WAM的数据来源、训练策略与应用场景
- 四、WAM的评测体系、核心挑战与未来方向

| 什么是世界模型？

语言模型

学习的是「文本」的统计结构

机器学会了「谈论」世界，但世界并非由文字构成。

世界模型

学习的是「空间与时间」的统计结构

光线如何落在表面、物体从未见过的角度是什么样、受力后如何运动——如何遵循物理规律。

「世界并不是由文字构成的。」 — 路德维希·维特根斯坦 《逻辑哲学论》

| 一个框架：智能体—世界交互闭环

源自强化学习的「部分可观测马尔可夫决策过程」(POMDP)——一切「世界模型」都是这一闭环的不同投影



🔄 闭环：观测反馈回智能体，循环往复

| 三类世界模型：闭环的不同投影

今天各种被称作「世界模型」的系统，各自输出闭环中的不同部分

渲染器

Renderer

输出：观测（像素 / 视频）

核心指标：视觉保真度

代表

文生视频、Google
Genie 3、
World Labs RTFM

模拟器

Simulator

输出：状态（几何/物理/
动态）

核心指标：结构性准确

代表

训练 RL 智能体、
机器人控制器的训练环
境

规划器

Planner

输出：行动

核心指标：能指导下
一步

代表

视觉-语言-行动模型、
World Action 模型

| 世界模型的基本定义

世界模型 = 能内化环境动力学和动作影响的预测模型
学习环境如何随动作而变化，从而支持模拟、规划和决策

核心状态转移



三大功能

模拟 Simulation

在想象中推演未来

规划 Planning


基于预测选择最优动作

决策 Decision

评估不同动作的后果

| 在MBRL里，世界模型是什么

模型式强化学习（Model-Based RL）中，世界模型是**"先想象再决策"**的核心机制：



| 第一类：理解世界的内部表征

学习**紧凑、抽象的隐变量表示**，抓住环境中对决策有用的结构，而非逐像素记忆世界。



核心优势



信息压缩

从高维观测中提取低维关键信息



噪声过滤

忽略与决策无关的视觉细节



结构学习

发现环境中的有用结构

| 第二类：预测未来的生成模型

从当前观察和条件出发**预测未来状态**，在视频世界模型中体现为生成后续帧或未来轨迹。

生成链路



输出形式



像素级生成

直接生成未来图像/视频帧

特征级生成

预测未来隐空间表示



轨迹级生成

预测未来状态序列

| 动作条件 vs 语言条件世界模型

动作条件

$$(o_t, a_t) \rightarrow o_{t+1}$$

输入：当前观察 + 具体动作

输出：执行该动作后的未来观察

特点：

- 动作是低层控制信号
- 精确预测特定动作后果

语言条件

$$(o_t, l) \rightarrow \text{future}$$

输入：当前观察 + 语言描述

输出：符合语言描述的未来

特点：

- 语言是高层语义约束
- 强调高层目标导向

| 显式世界模型 vs 隐式世界模型

显式世界模型

Explicit World Model

做法：直接预测像素、视频或几何结果

优点：

- ✓ 可解释性强，可视化直观
- ✓ 容易接入逆动力学模块

代价：

- ✗ 计算量大
- ✗ 长时预测误差累积

隐式世界模型

Implicit World Model

做法：在潜空间中建模动力学

优点：

- ✓ 计算高效，紧凑表示
- ✓ 聚焦控制相关信息

代价：

- ✗ 解释性较弱
- ✗ 依赖隐空间质量

| 像素级预测为什么重要



直观可视化

未来计划可以直接"看"到，便于理解和调试



易于对接

可接入逆动力学或视觉规划模块



人机交互

生成的视频可作为人机沟通媒介



可解释性强

便于分析模型预测的对错

典型流程

生成未来视频帧 → 视觉分析 → 提取动作参数 → 执行控制

| 但像素级预测为什么又不够好



计算量大

逐像素生成需要大量计算资源，推理速度慢



误差累积

长时滚动预测中，小误差逐步放大导致预测失真



关注错重点

过度关注视觉细节而非真正影响控制的物理因果



解决方向

- ✓ 使用**隐式表示**替代像素级预测，在潜空间中建模
- ✓ 采用**层次化预测**，粗到精逐步细化
- ✓ 引入**物理约束**，让模型学习真正的因果结构

| RSSM: 经典潜动力学框架

PlaNet和Dreamer系列使用RSSM，结合**确定性记忆**和**随机状态**，在潜空间中学习动力学：



确定性状态 h_t

RNN风格的循环隐藏状态

负责记忆历史信息



随机状态 z_t

变分推断的隐变量

捕捉环境的不确定性

组合状态 $s_t = [h_t, z_t]$

在潜空间中进行预测和规划

| Dreamer系列为什么重要

Dreamer证明世界模型不仅能做预测，还能直接支持RL中的**imagined rollouts**：



核心贡献



样本效率提升

在想象中生成大量训练数据，减少真实交互



端到端学习

世界模型与策略联合优化



SOTA性能

在多个连续控制基准上达到最优

| Transformer世界模型的出现

随着序列建模能力增强，研究者用**Transformer替代RNN**建模长时依赖：

RNN vs Transformer 时序建模

RNN 系列

- 顺序处理，难以并行
- 长时依赖容易遗忘
- 梯度消失/爆炸问题

代表： RSSM, PlaNet

Transformer 系列

- 自注意力捕获全局依赖
- 可并行处理，训练高效
- 长距离依赖建模能力强

代表： TSSM, TransDreamer

Trend: Transformer-based WM 成为主流，与LLM技术栈统一，便于Scale Up

| JEPA: 不一定要重建像素

JEPA (Joint Embedding Predictive Architecture) **直接预测抽象表示**而非重建原始输入:

JEPA 核心链路



与传统方法对比

传统方法 (重建)

预测原始像素 → 关注视觉细节
计算开销大, 易过拟合纹理

JEPA (预测表示)

预测抽象表示 → 关注可预测结构
高效, 关注真正重要的信息

| V-JEPA对世界模型的启发

V-JEPA将JEPA扩展到视频，用**潜表示预测**替代像素重建：

核心机制：视频块掩码预测



关键启发

抽象预测足够：不重建像素也能学到强大的世界表示

可服务控制：学到的表示可用于下游决策和规划任务

| 视频世界模型的技术底座

视频世界模型与视频生成技术紧密相关，经历以下技术演进：

- **GAN 时代**

- 生成对抗网络，训练不稳定但开创视频生成先河

- **U-Net 扩散**

- 扩散模型取代GAN，生成质量大幅提升，训练更稳定

- **ViT / DiT**

- 视觉Transformer将视频视为时空token序列，统一架构

- **Latent Diffusion**

- 在潜空间做扩散，效率与质量兼得，Sora等模型的基础

| VLA是什么

VLA = Visual-Language-Action Model

将机器人控制表述为多模态序列建模问题

VLA 基本架构



VLA是当前**通用机器人策略**的重要范式

核心思想：将控制问题转化为"条件生成问题"

输入视觉+语言 → 输出可执行动作

| VLA的典型融合方式

早期融合策略



特征调制

用语言特征调制视觉特征

交叉注意力

视觉-语言交叉注意力融合

简单拼接

直接拼接视觉和语言特征

动作生成头



自回归动作头

逐个预测动作token

适合离散动作空间



扩散动作头

生成连续动作分布

适合精细连续控制

| VLA的优势在哪里

语义泛化能力

借助大规模视觉语言预训练，理解开放词汇指令和新物体语义

跨任务迁移

同一策略可执行多个不同语言指令，具备任务泛化能力

数据效率高

利用互联网规模的视觉-语言数据预训练，减少机器人数据需求

统一框架

将感知、理解和控制统一到多模态序列建模框架中

| VLA的核心短板在哪里



核心短板：缺乏显式世界动态建模，在需要前瞻物理推理、长时计划和环境后果评估时容易失效

"Can a policy act without imagining consequences?"

具体表现

物理推理弱

无法理解推物体会使其移动

长时规划差

难以完成多步骤任务

后果评估缺失

不能预判危险操作

这正是 **WAM (World Action Model)** 出现的背景和动机

本节内容

CONTENTS

- 一、世界模型基础概念
- 二、世界动作模型的定义、分类与核心架构
- 三、WAM的数据来源、训练策略与应用场景
- 四、WAM的评测体系、核心挑战与未来方向

| 机器人策略学习的三类范式

直接模仿

Behavior Cloning / VLA

从专家演示直接回归动作；
VLA 把视觉-语言-动作统一到
大模型里。

- 数据效率高、上手快
- 泛化弱、缺乏对未来的显式预测
- 代表：RT-2、OpenVLA

想象中学习

Model-Based RL / World Model

学习环境动力学模型，在"想象"中规划或训练策略（
Dreamer 系）。

- 样本效率高、可规划
- 像素/状态预测与控制解耦
- 代表：Dreamer、DayDreamer

联合预测

Generative World Model / WAM

用生成式（视频扩散）世界模型，
联合预测未来世界状态与动作。

- 视频作稠密监督、强泛化
- 推理成本高、物理一致性待解
- 代表：DreamZero、DreamGen

| 概念页：World Model、VLA、WAM

World Model (WM)

学习"如果这样做会怎样"——预测未来观测/状态的生成或预测模型。

可在想象中规划，但本身不直接输出可执行动作。

Vision-Language-Action (VLA)

把图像、指令直接映射为动作的大模型策略。

动作直接，但缺乏对未来的显式建模，泛化依赖海量动作标注数据。


World Action Model (WAM)

在预训练视频扩散骨干上，联合预测未来世界状态与机器人动作。

视频提供稠密学习信号；动作与视觉共享表征——但推理需实时性。


核心张力： WAM 把"想象未来" (WM) 与"输出动作" (VLA) 耦合进同一个生成模型——收益是否真的来自测试时的未来想象，还是训练时的视频表征？

| 分类矩阵：WAM 的设计空间



第三维 (推理模式)： imagine-then-execute (测试时先想象再执行) vs representation-only (仅训练时用视频、推理跳过想象，如 Fast-WAM)

| 发展时间线：从 Dreamer 到 WAM



Source: [DayDreamer](#) · [RoboDreamer](#) · [DreamGen](#) · [DreamZero](#)

| WAM: 世界动作模型的正式定义

WAM = 同时统一环境动态建模与动作生成的具身基础模型
不仅要预测未来状态，还要让动作严格对齐于这些预测未来

核心公式

future, action = WAM(observation, instruction)

关键特征

统一建模

世界动态 + 动作生成

预测驱动

动作基于未来预测

对齐约束

动作与未来状态耦合

| WAM成立的两个必要条件

1 Forward Predictive Modeling

模型必须具备**前向预测建模**能力

能够生成或利用可量化的未来状态表征

不只是特征提取，而是真正的未来预测

例：预测“推杯子后杯子位置的变化”

2 Coupled Action Generation

动作生成必须和**未来状态耦合**

不是独立生成动作，而是基于预测未来
来生成

动作与未来预测之间有显式联系

例：根据预测到的杯子位置计算抓取轨迹

| WAM与普通世界模型的区别

普通世界模型

角色： 环境预测器

输入： 当前状态 + 动作

输出： 未来状态

局限：

- 只负责"预测"
- 不直接生成动作

WAM

角色： 预测 + 动作生成

输入： 当前观察 + 指令

输出： 未来状态 + 动作

优势：

- 预测服务于动作
- 端到端可学习

核心区别： WAM 把世界预测和动作控制放进**同一范式**，强调"预测未来是为了生成行动"，而非仅仅预测。

| WAM与VAM、Video Policy的区别

Video Policy

从视频直接输出动作
可能借用视频骨干特征
不一定有显式世界预测



VAM

视频动作模型
生成视频+动作
但局限于视频形式



WAM

最宽泛的概念
不要求视频形式
但要求显式世界
预测承诺

| WAM的总体分类

WAM

```
graph TD; WAM[WAM] --> Cascaded[Cascaded WAM 级联式]; WAM --> Joint[Joint WAM 联合式];
```

Cascaded WAM 级联式

先想象，再解码动作

流程：

预测未来状态 → 动作模块解码

特点：

- 结构清晰，两阶段解耦
- 可分别优化各模块

Joint WAM 联合式

预测和动作一体化

流程：

统一架构共同建模

特点：

- 共享表征，共同优化
- 强调因果耦合

| Cascaded WAM: 先想象, 再解码动作

Stage 1 预测未来

输入: 当前观察 + 指令

输出: 未来状态/计划表示

形式: 视频帧 / 隐表示 / 轨迹



Stage 2 解码动作

输入: 预测的未来表示

输出: 可执行动作

模块: 逆动力学 / 动作解码器

结构特点

优点:

- ✓ 结构清晰模块化
- ✓ 两阶段可独立优化
- ✓ 易于调试和替换

缺点:

- ✗ 两阶段耦合较松
- ✗ 预测误差影响动作
- ✗ 非端到端训练

| Joint WAM: 预测和动作一体化

统一架构

在一个统一架构中共同建模未来状态和动作，使两者共享表征并共同优化。


强调"未来预测"与"动作生成"的因果耦合。

架构示意



| 级联式的直观理解

对本科生来说，可以把级联式理解为：**"先脑补未来视频，再从视频里倒推出怎么做"**



本质

级联式 WAM 更像**显式规划流程**：先规划（预测未来），再执行（解码动作）。
与人类"先想清楚再动手"的直觉一致。

| 联合式更像真正的一体化代理

联合式 WAM 不把预测和控制拆开，而是在**同一模型内部**共同学习：



核心优势

两个任务互相促进

端到端梯度传播

更接近统一智能体

| 级联式中的显式规划

显式像素或视频规划路线：把**未来视频**当作**中间计划载体**

为什么用视频作为Plan Carrier



可解释

人类可以直接观看理解



直观

视觉化的计划表示



易展示

便于人机交互和调试

流程

当前观察



生成未来视频
Plan Carrier



逆动力学解码动作

| 级联式中的隐式规划

不生成完整视频，只预测**潜空间未来表征**，再从表征中解码动作：

隐式规划流程



相比显式规划的优势



更高效

无需生成完整视频帧



更聚焦

只保留控制相关信息



更紧凑

低维表示节省存储

| 显式规划的优点与代价

✓ 优点

1. 可解释性强

生成的视频可以直接观看和验证

2. 可视化强

便于调试和展示

3. 容易对接

可与逆动力学模块直接对接

✗ 代价

1. 计算量大

生成视频需要大量计算资源

2. 时延高

视频生成速度慢，影响实时性

3. 误差累积

长时预测误差逐步放大

| 隐式规划的优点与代价

✓ 优点

1. 紧凑高效

低维表示，计算开销小

2. 聚焦控制

重点放在控制相关表征上

3. 推理快速

潜空间操作速度快

✗ 代价

1. 解释性弱

隐表示难以直接理解

2. 质量依赖

依赖潜空间是否保留物理因果

3. 调试困难

难以可视化中间结果

| 联合式WAM的两类生成头

联合式 WAM 中，根据生成方式可分为两大类：

→ 自回归范式

Autoregressive

把未来和动作看作token序列
逐个token自回归生成

优势：

- ✓ 与LLM范式兼容
- ✓ 序列建模清晰

局限：

- ✗ 长序列效率问题

扩散/流匹配

Diffusion / Flow Matching

联合生成未来状态和动作
通过去噪过程生成

优势：

- ✓ 建模多模态分布
- ✓ 生成质量高

局限：

- ✗ 推理时延较大

| Autoregressive Joint WAM

自回归式方法：将未来和动作表示为token序列，**逐个生成**：

$[obs_token] \rightarrow [future_token_1] \rightarrow [future_token_2] \rightarrow [action_token_1] \rightarrow \dots$

优势



LLM范式兼容

可直接使用大语言模型架构



序列建模清晰

因果关系明确



易于扩展

支持多模态token统一


限制

长序列生成效率低，误差累积问题，推理速度受限

| Diffusion-based Joint WAM

扩散式方法：通过**去噪过程**联合生成未来状态和动作：

去噪流程



优势

多模态建模

擅长建模多模态未来分布

高质量生成

连续动作生成质量高

局限：推理时延

多步去噪过程导致推理慢

| Unified Stream: 一个主干包办两件事

Unified Stream 把未来预测和动作生成编码进**同一预测流**:



核心特点

结构统一

单一网络处理所有任务

共享充分

所有参数共享

目标关键

训练目标设计更重要

| Multi-Stream: 多分支协同

Multi-Stream 给 world branch 和 action branch **分开建模**，再交换信息：



信息交换机制


交叉注意力 Cross-Attention

隐藏状态 Hidden States

共享表示 Shared Repr

| Cross-Attention Coupling


世界分支和动作分支结构独立，在多个层级通过**交叉注意力**交换信息：



| Hidden-State Coupling

世界分支生成**隐藏状态**，作为条件提供给动作分支：

信息流动



优势



降低推理成本：无需生成完整视频




信息压缩：隐藏状态是紧凑的表示

| Shared Representation Coupling

世界预测与动作生成**共享同一潜表示**，再由不同轻量头解码：

架构



优势

训练更统一 | 推理更灵活 | 参数更高效

| 为什么"预测未来"能帮助"生成动作"

动作不再只依赖当前观察，而是依据"未来可能会发生什么"来做选择：

物理理解

预测未来需要理解物理规律，这种理解自然提升动作质量

泛化能力

理解"什么导致什么"后，更容易泛化到新场景

安全性

能预判危险后果，避免执行有害动作

规划能力

预测使系统能进行"如果...就..."的推理

| 多模态未来：视觉不是全部

当前 WAM 大多局限于RGB预测，但接触丰富操作还需要更多模态：



RGB

视觉图像



Depth

深度信息



Force

力觉反馈



Tactile

触觉传感



Proprio

本体感知

为什么需要多模态

接触丰富的操作（如抓取、装配）仅靠视觉不足以判断：

- 力觉告诉"抓得够不够紧"
- 触觉告诉"表面是什么材质"
- 本体感知告诉"手臂在哪里"

DreamZero (一)：问题动机

- VLA 的瓶颈：泛化依赖海量、昂贵的机器人动作标注，面对未见任务/物体/具身时表现脆弱。
- 海量"无动作"视频（其他机器人、人类示范）蕴含丰富的物理与任务知识，却难以直接训练策略。
- 核心问题：能否把预训练视频生成模型的世界知识，直接转化为零样本可执行的机器人策略？

DreamZero 的主张

在预训练视频扩散骨干上联合预测未来世界状态与动作，使视频成为稠密的学习信号——把"看会做"转化为"零样本去做"。

> 2×

真实机器人实验中相对 SOTA VLA 的泛化提升

7 Hz

14B 自回归视频扩散模型实时闭环控制频率

+42%

仅 10–20 min 他者视频示范带来的未见任务提升

DreamZero (二) : 架构与联合建模



闭环：执行后回灌新观测，自回归滚动预测下一步 (7 Hz 实时)

联合而非级联

视频帧与动作在同一生成过程中被预测，动作与视觉表征共享，避免级联误差。

视频作稠密监督

未来帧预测为动作学习提供逐像素的稠密信号，降低对动作标注的依赖。

零样本策略

世界模型的预测能力直接被解读为可执行策略，无需任务特定微调即可迁移。

DreamZero (三) : 训练数据与目标

预训练

在大规模互联网与机器人视频上预训练视频扩散骨干，习得通用物理与场景动力学先验。

联合目标

在带动作标注的机器人数据上联合优化：未来帧的扩散去噪损失 + 动作预测损失。

无动作视频

其他机器人、人类示范视频以"仅视频"形式参与，提供任务语义与运动模式监督。

数据信号的层级

互联网视频

最丰富 · 通用物理先验

他者机器人 / 人类视频

中等 · 任务语义、运动模式

目标机器人动作数据

最稀缺 · 精确动作对齐

DreamZero (四) : 实验结论与评价

> 2×

泛化提升

真实机器人实验中相对
SOTA VLA

+42%

未见任务

仅 10–20 min 他者视频
示范 (video-only)

30 min

新具身适配

用约 30 min play data
适配新机器人

7 Hz

实时闭环

14B 自回归视频扩散完
成实时控制

优点

- 零样本/弱监督泛化显著优于 VLA 基线
- 可吸收无动作视频，数据来源大幅拓宽
- 联合建模实现实时闭环 (7 Hz)，具落地性
- 低成本跨具身适配 (30 min play data)

局限

- 14B 模型推理成本高，实时性靠工程优化勉强达成
- 生成视频的物理一致性、长时序漂移仍受质疑
- "想象未来"是否真带来收益尚待消融 (见 Fast-WAM)
- 结果多为论文自报真实机器人实验，复现门槛高

代表工作横向对比

论文	表征 / 动作接口	数据来源	推理模式	核心贡献 · 解决的问题
DreamGen	Pixel · 伪动作(IDM/潜动作)	视频世界模型生成的合成轨迹	Cascaded	4 阶段管线生成神经轨迹；单一抓放遥操作数据→人形机器人 22 种新行为
DreamDojo	Latent · 连续潜动作代理	44k 小时第一视角人类视频	Cascaded	从大规模人类视频学通用机器人世界模型；实时 10.81 FPS，支持遥操/评估/规划
WorldVLA	Pixel · 自回归动作 token	机器人图像-动作序列	Joint	统一动作与图像理解/生成；注意力掩码策略改进动作块生成
AdaWorld	Latent · 自监督潜动作	无标注视频	Joint	从视频自监督学潜动作；少量交互/微调即可适配新世界
RoboScape	Pixel + 物理先验	RGB 视频 + 深度/关键点	Joint	物理信息具身世界模型；时序深度与关键点动力学；服务策略训练/评估
FlowDreamer	RGB-D · 3D 场景流	机器人 RGB-D 序列	Cascaded	显式 3D 场景流再扩散未来帧；提升语义相似度/像素质量/成功率
BridgeV2W	Pixel · 具身掩码控制	URDF/相机渲染的具身掩码	Cascaded	坐标动作→像素对齐具身掩码(ControlNet 式)；策略评估与目标条件规划
Motus	Latent · 光流潜动作	多任务理解/视频/动作	Joint	Mixture-of-Transformer 统一专家；UniDiffuser 式调度支持 WM/VLA/IDM/联合预测
Fast-WAM	Pixel · 视频协同训练	机器人视频 + 动作	Repr.-only	质疑测试时想象；保留视频协同训练但推理跳过未来预测；190ms, >4× 提速

Source: [arXiv 各论文](#) · [Fast-WAM Project](#) · [FlowDreamer RA-L](#)

本节内容

CONTENTS

- 一、世界模型基础概念
- 二、世界动作模型的定义、分类与核心架构
- 三、WAM的数据来源、训练策略与应用场景
- 四、WAM的评测体系、核心挑战与未来方向

| 为什么数据是WAM的瓶颈

动作对齐数据

需要严格动作对齐的机器人演示数据，
用于学习精确控制

物理先验数据

希望吸收互联网视频的大规模物理先验
，学习通用物理知识

矛盾与挑战

机器人数据：动作精确但规模小、场景有限

互联网视频：规模大但缺少动作标签

WAM 需要同时利用两者，数据需求比 VLA 更复杂

| 四类核心数据来源总览

1 机器人遥操作

精确动作对齐的 (o_t, a_t, o_{t+1}) 三元组
质量高但采集昂贵

2 人类示范

便携式设备采集的人类操作数据
场景丰富但需动作重定向

3 仿真数据

程序生成的合成数据
易扩展但存在sim-to-real gap

4 互联网视频

大规模人类视频 (Ego4D等)
物理先验丰富但无动作标签

| 机器人遥操作数据

提供高频、精确、动作对齐的 (o_t, a_t, o_{t+1}) 三元组:

o_t (当前观察) + a_t (执行动作) $\rightarrow o_{t+1}$ (下一观察)

精确的动作条件动力学数据

为什么是最可靠的数据来源



动作精确

遥操作记录真实控制信号



因果对齐

动作与观测严格对应



高质量

人类专家级操作示范

| 遥操作数据的优点与限制

✓ 优点

1. 动作真实

记录真实控制信号

2. 控制精确

高频精确采集

3. Sim-to-real gap小

直接在真实机器人上采集

✗ 限制

1. 采集昂贵

需要人类操作员和设备

2. 环境封闭

通常固定场景

3. 形态多样性不足

针对特定机器人类型

| 便携式人类示范数据 (UMI路线)

UMI (Universal Manipulation Interface) 通过**便携设备**在真实环境中采集人类操作：

UMI 数据流程



核心作用

连接"真实世界丰富性"和"可执行动作"的重要桥梁
在真实环境中采集 → 对齐到机器人动作 → 用于训练WAM

| 为什么UMI风格数据很重要

保留场景多样性

在真实野外场景中采集，保留环境的丰富性和多样性

接近控制约束

提供比纯互联网视频更接近机器人控制的动作约束

对WAM学习的关键价值

UMI风格数据让WAM能够学习**现实物理变化**，而非仅限于仿真环境。
这是连接"人类世界"和"机器人世界"的关键数据类型。

| 仿真数据的作用

仿真数据的优势



易扩展

可程序生成大量数据



可控

精确控制场景参数



特权信息

深度、法向、分割等

特权几何监督

仿真环境可提供真实世界难以获取的**3D/4D监督信号**：

● 深度图 Depth ● 表面法向 Normal ● 点云 Point Cloud ● 语义分割 Segmentation

这些特权信息对3D/4D世界建模至关重要

| 互联网和第一视角人类视频的作用

大规模人类视频缺少精确动作标签，但提供**海量物理先验**：

代表性数据集

Ego4D | EPIC-KITCHENS | HowTo100M | Something-Something

核心价值



物体交互先验

人类如何与物体交互



物理常识

重力、碰撞等物理规律



开放场景

多样化的真实环境

| 动作缺失怎么办：推断Latent Action

互联网视频没有动作标签，如何从中学习？推断潜在动作：

Latent Action 推断流程



代表性工作

Genie

从视频中学习潜在动作

DreamDojo


大规模视频动作学习

SWIM

无监督动作发现

| 数据混合为什么是WAM的独特优势

WAM 既能用高质量动作数据学习控制，也能吸收无动作视频学习物理先验：



相比VLA的优势

VLA 只能使用动作标注数据，而 WAM 可以**天然利用多源数据联合训练**

| 数据混合的关键问题

数据混合仍是**开放问题**，核心挑战包括：



多少数据？

每种数据源的边际价值
是什么？



什么顺序？

最佳课程学习路径是什么？



怎么过滤？

如何筛选高质量数据？

这些问题目前尚无定论，是 WAM 领域的重要研究方向。

需要大量实证研究来探索最优数据混合策略。

| 世界模型如何帮助模仿学习

世界模型可以**合成或筛选训练轨迹**，提升训练样本的多样性与覆盖范围：

世界模型辅助模仿学习



核心作用

数据增强

合成多样化训练样本

覆盖扩展

探索专家未覆盖的状态

安全探索

在想象中安全试错

| 世界模型如何帮助强化学习

世界模型作为 **surrogate environment**，供 agent 在想象空间中试错：

真实环境 vs 想象环境

真实环境交互

- ✗ 成本高（硬件损耗）
- ✗ 有风险（可能损坏）
- ✗ 速度慢（物理时间）

想象环境交互

- ✓ 成本低（纯计算）
- ✓ 无风险（虚拟环境）
- ✓ 速度快（并行推演）

核心收益：大幅减少真实环境交互成本和风险，同时提升样本效率

| 世界模型如何充当奖励模型

利用世界模型的**预测一致性**来构造奖励，减少手工奖励设计：

奖励构造流程



可使用的信号

预测一致性

预测与实际的一致性

分布熵

生成分布的多样性

目标对齐

与目标状态的接近度

| 世界模型如何帮助策略评测

世界模型作为**数据驱动模拟器**，不上机即可批量测试策略：

评测流程



评测能力

批量测试

大量场景快速评估

OOD场景生成

测试分布外泛化

安全红队

主动发现策略缺陷

| 物理模拟器和世界模型如何协同

物理模拟器

强项：显式物理、可控实验

弱项：建模真实分布有限

世界模型

强项：数据驱动、拟合真实分布

弱项：物理精确性有限

协同 → 缩小 Sim-to-Real Gap

| 应用一：机械臂操作

世界模型在机械臂操作中的应用是**最活跃的方向**之一：



抓取

预测抓取后果



推物

生成训练数据



装配

辅助长时规划

机械臂操作是 WAM 的**核心应用场景**

世界模型用于预测抓取后果、生成训练数据、辅助长时操作规划

桌面操作任务是最常见的评估场景

| 应用二：人形与移动机器人

世界模型在人形和移动平台中的关键应用：



地形预判

预测地面情况，提前调整步态



导航规划

预测路径上的动态变化



全身控制

协调多关节运动



长时任务

执行复杂多步骤任务

本节内容

CONTENTS

- 一、世界模型基础概念
- 二、世界动作模型的定义、分类与核心架构
- 三、WAM的数据来源、训练策略与应用场景
- 四、WAM的评测体系、核心挑战与未来方向

| 为什么评测比"视频好不好看"更难



WAM 不仅要生成**看起来合理**的未来，还要保证这些未来对**动作决策真正有用**。因此不能只用视觉质量衡量好坏。

评测维度

视觉保真度

物理正确性

动作可执行性

下游成功率

四个维度缺一不可，共同构成 WAM 的完整评测体系

| 第一类评测：视觉保真度

评估生成未来的**视觉质量**，常用指标包括：

常用指标

PSNR

峰值信噪比

SSIM

结构相似性

LPIPS

感知相似性

FVD

视频分布距离

DreamSim

语义相似性

局限性

视觉保真度只衡量"看起来真不真"，不衡量"物理对不对"或"动作是否可行"。

高视觉质量 $\neq$ 好的世界模型

| 第二类评测：物理常识与物理正确性

模型应符合**重力、碰撞、材质和因果**等物理常识：

代表性评测基准

VideoPhy

视频物理正确性评测

PhyGenBench

物理生成基准

Physics-IQ

物理推理评测

评测维度

重力遵循 | 碰撞合理性 | 材质一致性 | 因果关系 | 时间连续性

| 第三类评测：动作可执行性

WAM 生成的未来必须包含足够的**行动信息**，能否反推出可执行动作：

Action Plausibility 评测流程



评判标准

动作合理性

解码的动作是否在机器人可达范围内

执行成功率

动作执行后是否达到预期效果

| 第四类评测：下游任务成功率

最终看下游操作、导航、装配等**任务是否成功完成**：

代表性评测基准

MetaWorld

元操作任务

RLBench

机器人学习基准

LIBERO

长时操作基准

RoboCasa

家庭机器人基准

核心指标

Success Rate = 任务成功次数 / 总尝试次数

这是衡量 WAM 实用价值的最终标准

| 现有评测的根本问题



核心问题："世界预测"和"动作生成"常被**分开评测**

这违背了 WAM 强调两者因果耦合的初衷

好的世界预测 + 好的动作 $\neq$ 好的 WAM

世界预测排行榜 $\longleftrightarrow$ 动作生成排行榜

?

两者之间的因果一致性被忽略

| 未来评测方向：联合评估因果一致性

理想评测应同时检验 imagined future 和 generated action 是否**因果一致**：

✓ Counterfactual Consistency

反事实一致性：改变动作，未来是否相应变化？

👁 Foresight-Conditioned Success

前瞻条件成功率：动作是否遵循所想象的
的未来计划？

愿景：建立统一的 WAM 评测框架

同时衡量世界预测质量、动作生成质量、以及两者的因果一致性

| 挑战一：长时任务与层次规划

当前 WAM 多在**短时操作任务**上评估，通用具身智能需要解决长时任务：

当前：短时抓取

单步或几步操作

误差累积有限

挑战：长时整理桌面

多步骤复杂任务

误差累积严重

核心难题

分布漂移

长时执行中状态偏移

误差累积

每步小误差逐步放大

层次分解

任务如何分解为子目标

| 挑战二：物理规律与反事实推理

大模型可能学到**相关性而非真正因果**，如何学到稳健的物理规律？

核心问题：模型知道"球通常会下落"，但不知道"如果推得更重，球会飞得更远"
缺乏反事实推理能力

反事实推理示意

"轻推杯子"
→ 杯子移动一点

"重推杯子"
→ 杯子移动很多？

"不推杯子"
→ 杯子不动？

| 挑战三：效率与时延

把世界预测纳入闭环控制带来**严重延迟负担**：

控制频率对比

常规 VLA

控制频率：10-50 Hz

实时性较好

扩散/视频 WAM

控制频率：1-5 Hz

难以达到实时控制

瓶颈来源

多步去噪扩散

高分辨率视频生成

长序列自回归

| 挑战四：安全、可靠性与可验证性

WAM 能预测未来，但如果**预测错了**，可能更自信地执行危险动作：



风险悖论：错误的未来预测 → 错误的动作信心 → 危险执行
模型"以为"自己知道未来，但实际上预测有误

解决方向



不确定性估计

量化预测不确定性



安全验证

推理时验证动作安全性



保守策略

不确定时选择安全动作

问题和讨论

